ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

BÁO CÁO CUỐI KỲ

MÔN: HỆ HỖ TRỢ RA QUYẾT ĐỊNH DỰA TRÊN DỮ LIỆU

ĐỀ TÀI

HỆ HỖ TRỢ RA QUYẾT ĐỊNH SINH CÂU HỎI TRẮC NGHIỆM LỊCH SỬ

Nhóm Học viên thực hiện: Nhóm 10
1. Nguyễn Bình Nguyên - 250201078
2. Trần Võ Bảo Thiên - 240104052
3. Trần Ngọc Phú - 2502010243
4. Hoàng Hải Đăng - 2502010484
5. Trần Anh Hào - 250201058

Giảng viên hướng dẫn: TS. Lê Thanh Tùng

TP. Hồ Chí Minh, tháng 7 năm 2026

MỤC LỤC

1. GIỚI THIỆU VÀ BÀI TOÁN DSS 10
1.1. Bối cảnh và động lực 10
1.2. Kiến trúc DSS 3 tầng 10
1.3. Input, Output và Taxonomy 11
2. NGUỒN DỮ LIỆU 12
2.1. Nguồn 1 - UIT-ViQuAD 2.0 12
3. PHÂN TÍCH DỮ LIỆU (EDA) 14
3.1. Thống kê corpus lịch sử 14
3.3. Knowledge Base thực thể (NER) 15
3.4. Phân bố Bloom - VNHSGE-History 16
4. TIỀN XỬ LÝ DỮ LIỆU 18
4.1. Pipeline tổng thể 18
4.2. Schema MCQItem – Pydantic v2 19
5. CÁC PHƯƠNG PHÁP SINH CÂU HỎI 20
5.1. Phương pháp 1 - Rule-Based 20
5.2. Phương pháp 2 - RAG+LLM 21
5.3. Phương pháp 3 - ViT5 Fine-tuning 23
6. MODULE KIỂM CHỨNG (VERIFIER) 26
6.1. 8 tiêu chí kiểm định 26
6.2. Tận dụng nhãn vàng is_impossible 26
7. TẦNG DSS: AHP/TOPSIS 28
7.1. AHP - Xác định trọng số tiêu chí 28
7.2. TOPSIS - Xếp hạng 3 phương án 29
7.3. Phân tích độ nhạy 30
8. TẦNG DSS: RÁP ĐỀ THI (ILP) 31
9. KẾT QUẢ SO SÁNH 32
9.1. Kết quả Verifier - Tổng quan 32
9.2. Bảng so sánh toàn diện 32
9.3. Kỳ vọng vs Thực tế 33
9.4. Kết luận DSS - Chiến lược định tuyến 33
10. HỆ THỐNG DASHBOARD 35
11. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 38
11.1. Đóng góp chính 38
11.2. Hạn chế 38
11.3. Hướng phát triển 39

DANH MỤC HÌNH ẢNH

Số hiệu	Tên hình
Hình 1.1	Kiến trúc hệ thống DSS 3 tầng cho bài toán sinh MCQ lịch sử
Hình 2.1	Mẫu dữ liệu UIT-ViQuAD 2.0 - schema và ví dụ câu hỏi lịch sử
Hình 2.2	Cấu trúc thư mục VNHSGE-History trên GitHub
Hình 3.1	Phân bố corpus lịch sử ViQuAD 2.0 theo split, tiểu miền và độ dài
Hình 3.2	Pipeline chia split chống rò rỉ dữ liệu theo title-level
Hình 3.3	So sánh NER precision trước và sau cải tiến (underthesea → ELECTRA)
Hình 3.4	Kết quả chấm tay 100 mẫu NER - precision theo entity type
Hình 3.5	Phân bố Bloom VNHSGE-History và F1 của Bloom classifier
Hình 4.1	Pipeline tiền xử lý dữ liệu từ nguồn thô đến Knowledge Base
Hình 4.2	Cấu trúc schema MCQItem - chuẩn chung cho 3 phương pháp sinh câu hỏi
Hình 5.1	Pipeline Rule-Based Generator - 3 lớp luật xử lý
Hình 5.2	Kết quả chạy Rule-Based Generator - output terminal và mẫu câu hỏi
Hình 5.3	Pipeline RAG+LLM - Hybrid retrieval (BM25+FAISS) kết hợp GPT-4o-mini
Hình 5.4	Kết quả chạy RAG+LLM Generator - output terminal với tiến trình từng câu
Hình 5.5	Training loss Stage A (QG) và Stage B (DG) theo epoch - ViT5-base fine-tuning
Hình 5.6	Output terminal quá trình train ViT5 Stage A - loss giảm theo epoch
Hình 5.7	Output terminal ViT5 inference - câu hỏi và distractor sinh được + thống kê
Hình 6.1	Tận dụng is_impossible của ViQuAD 2.0 làm nhãn vàng Evidence Match
Hình 6.2	So sánh chi tiết VNHSGE Classifier vs GPT zero-shot trên 90 câu mẫu
Hình 7.1	Ma trận so sánh cặp AHP 8×8 - thang Saaty 1–9
Hình 7.2	Trọng số AHP của 8 tiêu chí kiểm định
Hình 7.3	Sơ đồ tính toán TOPSIS và kết quả xếp hạng 3 phương pháp
Hình 7.4	Phân tích độ nhạy - TOPSIS score khi trọng số VQR thay đổi 1%→50%
Hình 8.1	Kết quả ráp đề ILP vs Greedy vs Random - phân bố Bloom và mẫu câu hỏi
Hình 9.1	Output terminal Verifier - kết quả 3 phương pháp sau khi kiểm định 8 tiêu chí
Hình 9.2	Radar chart so sánh 3 phương pháp trên 8 tiêu chí Verifier
Hình 9.3	Grouped bar chart so sánh 8 tiêu chí Verifier - 3 phương pháp
Hình 9.4	Chiến lược Hybrid Routing DSS - định tuyến phương pháp theo ngữ cảnh
Hình 10.1	Dashboard - Trang Tổng quan: KPI và bảng so sánh 3 phương pháp
Hình 10.2	Dashboard - Trang Demo: nhập context tự do, xem 3 phương pháp song song

Hình 10.3	Dashboard - Trang AHP/TOPSIS Realtime: kéo slider trọng số → thứ hạng đổi ngay
Hình 10.4	Dashboard - Trang Ráp đề: ILP tối ưu có ràng buộc Bloom + download đề thi

DANH MỤC BẢNG BIỂU

Số hiệu	Tên bảng
Bảng 1.1	Taxonomy Wh-type - 6 loại câu hỏi và đặc điểm
Bảng 2.1	Thông tin nguồn dữ liệu 1 - UIT-ViQuAD 2.0
Bảng 2.2	Thông tin nguồn dữ liệu 2 - VNHSGE môn Lịch sử
Bảng 3.1	Thống kê corpus lịch sử sau khi lọc từ ViQuAD 2.0
Bảng 3.2	Phân bố split dữ liệu theo bài, đoạn và câu hỏi
Bảng 3.3	Kết quả NER precision theo entity type - ELECTRA + clean_entities
Bảng 3.4	Phân bố Bloom trong VNHSGE-History và F1 Bloom classifier
Bảng 5.1	Thông số sinh câu hỏi - Rule-Based Generator
Bảng 5.2	Thông số sinh câu hỏi - RAG+LLM Generator
Bảng 5.3	Thông số huấn luyện ViT5 Fine-tuning
Bảng 5.4	Thông số inference ViT5 Fine-tuning
Bảng 6.1	8 tiêu chí kiểm định Verifier - phương pháp đo và trọng số AHP
Bảng 6.2	So sánh Bloom Fidelity: VNHSGE Classifier vs GPT zero-shot
Bảng 7.1	Trọng số AHP 8 tiêu chí kiểm định
Bảng 7.2	Kết quả xếp hạng TOPSIS - 3 phương pháp sinh MCQ
Bảng 7.3	Điểm mạnh tương đối từng phương pháp theo tiêu chí
Bảng 8.1	So sánh 3 chiến lược ráp đề: ILP vs Greedy vs Random
Bảng 9.1	Bảng so sánh toàn diện 3 phương pháp - số liệu thật từ Verifier
Bảng 9.2	Kỳ vọng vs Thực tế - phân tích nguyên nhân chênh lệch
Bảng 9.3	Chiến lược định tuyến DSS - phương pháp khuyến nghị theo tình huống
Bảng 10.1	Chức năng 5 trang Dashboard Streamlit

BẢNG PHÂN CÔNG CÔNG VIỆC

STT	Thành viên	Vai trò	Nội dung công việc chi tiết	Đóng góp
1	**Nguyễn Bình Nguyên - 250201078**	**Nhóm trưởng**	**[Khởi động & Dữ liệu]** • Thiết kế kiến trúc tổng thể hệ thống DSS 3 tầng	**24%**
			• Xây dựng pipeline tiền xử lý: survey_viquad.py, build_corpus.py	
			• Phân tích và lọc corpus lịch sử từ ViQuAD 2.0 (38 bài, 1,862 đoạn)	
			• Thiết kế schema MCQItem (Pydantic v2) và 4 bất biến validator	
			• Rà tay 184 bài Wikipedia, đánh nhãn is_history/is_vietnam	
			[NER & Knowledge Base] • Xây dựng ner_kb.py - tích hợp ELECTRA + regex YEAR/DATE/CENTURY	
			• Phát hiện lỗi underthesea (LOC 41%) và chuyển sang ELECTRA	
			• Viết clean_entities.py (7 luật lọc) - nâng LOC precision lên 97%	
			• Chấm tay 100 mẫu NER để đánh giá precision theo entity type	
			• Quản lý tiến độ nhóm và phân công nhiệm vụ	
			[Viết báo cáo & Slide] • Tổng hợp và viết báo cáo hoàn chỉnh (BAO_CAO_HHTQD_v2.docx)	
			• Soạn đề cương slide báo cáo (SLIDE_OUTLINE.md)	
			• Soạn script lời dẫn + Q&A hội đồng (SCRIPT_QA.md)	
			• Tạo danh mục hình, danh mục bảng và bảng phân công	
2	**Trần Võ Bảo Thiên - 240104052**	**Thành viên**	**[Rule-Based Generator]** • Xây dựng rule_based.py - 3 lớp luật (NER, Template, Distractor)	**19%**
			• Thiết kế distractor pool theo (type, bucket) thế kỷ	
			• Triển khai fallback mechanism khi pool thiếu distractor	
			• Chạy sinh 423 câu hỏi trên tập train và ghi kết quả	
			• Phân tích điểm yếu Duplicate Check=0.080 do template cứng	
			[Verifier - Tiêu chí 1-4]	

			• Implement check_evidence_match() dùng NLI GPT-4o-mini	
			• Implement check_single_correct() kiểm tra 4 phương án	
			• Implement check_distractor_type() dùng NER + cosine similarity	
			• Implement check_historical_correctness() đối chiếu KB	
			• Tích hợp nhãn vàng is_impossible vào Evidence Match	
			[EDA & Phân tích dữ liệu] • Xây dựng EDA notebook (eda_notebook.ipynb) - 19 cells	
			• Vẽ biểu đồ phân bố corpus, split, NER, Bloom VNHSGE	
			• Phân tích year_density và đặc điểm corpus lịch sử	
3	**Trần Ngọc Phú - 2502010243**	**Thành viên**	**[RAG+LLM Generator]** • Xây dựng build_index.py - BM25 + FAISS/vi-bi-encoder	**19%**
			• Implement HybridRetriever với Reciprocal Rank Fusion (RRF)	
			• Thiết kế few-shot prompt ép evidence_sentence nguyên văn	
			• Xây dựng rag_llm.py với retry logic (JSON parse error)	
			• Chạy sinh 90 câu hỏi, tổng chi phí $0.0174	
			[Verifier - Tiêu chí 5-8] • Implement check_question_clarity() - heuristic độ dài, đại từ	
			• Implement check_duplicate() - Jaccard trigram similarity	
			• Implement check_answer_position() - phân bố A/B/C/D	
			• Tích hợp VNHSGE Bloom classifier vào check_bloom_fidelity()	
			• Xây dựng luồng verify_file() và tổng hợp verifier_score	
			[Kiểm thử & Tích hợp] • Viết test_verifier.py và test_rag_llm.py	
			• Chạy Verifier trên 810 câu - bloom_backend=both	
			• Phân tích kết quả so sánh CLF vs GPT (agreement=76%)	

4	**Hoàng Hải Đăng - 2502010484**	**Thành viên**	**[ViT5 Fine-tuning]** • Chuẩn bị dữ liệu train Stage A (QG) và Stage B (DG)	**19%**
			• Xây dựng train_vit5.py với fp16, gradient accumulation	
			• Implement checkpoint resume khi máy tắt giữa chừng	
			• Train Stage A (dev loss ~1.78) và Stage B (dev loss ~1.99)	
			• Phân tích hạn chế DG không học format separator |	
			[ViT5 Inference & Fallback] • Xây dựng infer_vit5.py với fallback entity từ context	
			• Giải quyết lỗi EncoderDecoderCache và GradScaler trên Colab	
			• Chạy inference 297 câu trên tập test	
			• Phân tích phân bố distractor: 63% đủ 3/3, 37% fallback	
			[VNHSGE Bloom Classifier] • Tải 50 file JSON VNHSGE-History từ GitHub	
			• Gán nhãn Bloom bằng heuristic từ khoá (4 mức)	
			• Train TF-IDF + Logistic Regression (accuracy=90%)	
			• Tích hợp bloom_classifier.pkl vào Verifier pipeline	
5	**Trần Anh Hào - 250201058**	**Thành viên**	**[AHP/TOPSIS]** • Xây dựng ahp_topsis.py - tính trọng số AHP (CR=0.023)	**19%**
			• Implement TOPSIS 5 bước theo Hwang & Yoon (1981)	
			• Phân tích độ nhạy VQR 1%→50% (không có điểm giao)	
			• Xuất báo cáo DSS: ahp_weights.csv, topsis_ranking.csv	
			• Tạo AHP_MATRIX.docx - ma trận 8×8 màu sắc + thang Saaty	
			[ILP Ráp đề thi] • Xây dựng exam_builder.py - bài toán ILP với PuLP/CBC	
			• Implement 4 ràng buộc: K câu, Bloom ±1, title≥1, context≤2	
			• So sánh ILP vs Greedy vs Random (ILP đạt +22.8% vs Random)	
			• Xuất exam_ilp.csv, exam_greedy.csv, strategy_comparison.csv	

			[Dashboard Streamlit] • Xây dựng dashboard.py - 5 trang Streamlit	
			• Trang AHP/TOPSIS Realtime với 8 slider trọng số	
			• Trang Demo Sinh Câu Hỏi - 3 phương pháp song song	
			• Trang Ráp đề thi - ILP tích hợp + download CSV	
			• Kiểm thử toàn bộ hệ thống end-to-end	
TỔNG CỘNG				**100%**

Ghi chú:

• Tổng đóng góp: 24% + 19% × 4 = 100%

• Nhóm trưởng phụ trách thêm: quản lý tiến độ, tổng hợp báo cáo, phối hợp phân công.

• Tất cả thành viên đều tham gia kiểm thử (test) và demo hệ thống.

1. GIỚI THIỆU VÀ BÀI TOÁN DSS

1.1. Bối cảnh và động lực

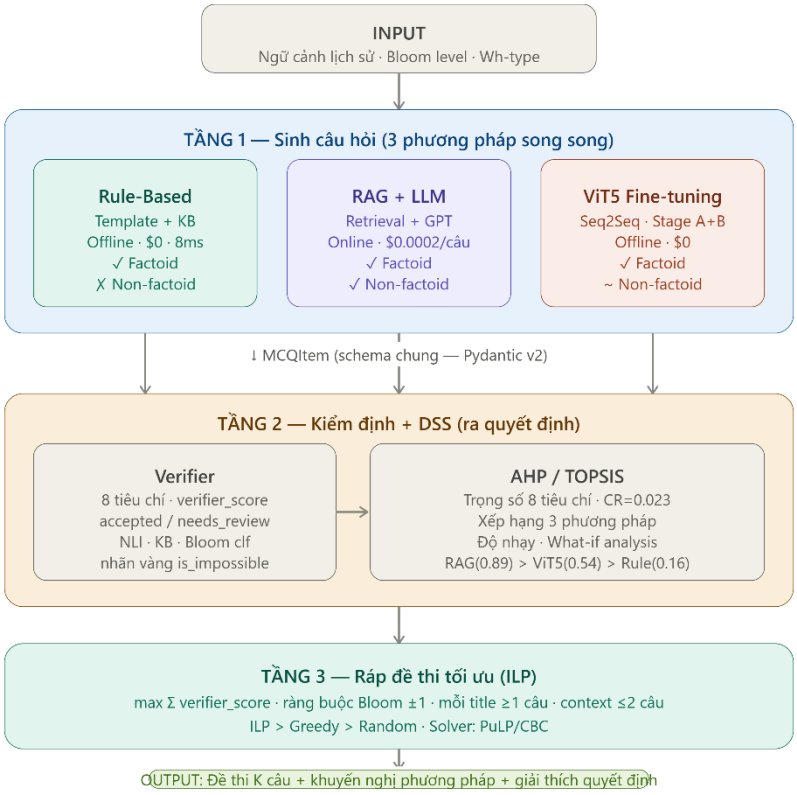
Trong bối cảnh đổi mới giáo dục và thi cử hiện nay, giáo viên lịch sử ngày càng cần xây dựng ngân hàng câu hỏi trắc nghiệm chất lượng cao và đa dạng. Một đề thi chuẩn cần đảm bảo phân bố Bloom đúng ma trận đặc tả (40% Nhận biết, 35% Thông hiểu, 25% Vận dụng), đồng thời phủ đều các chủ đề chương trình.

Việc soạn thủ công 40 câu hỏi cho một đề thi mất khoảng 2-3 giờ. Câu hỏi thủ công dễ bị trùng lặp khi ngân hàng câu hỏi tích lũy theo thời gian, và rất khó kiểm soát phân bố độ khó nhất quán giữa các đề.

Bài toán đặt ra: Làm thế nào để tự động hoá quá trình sinh câu hỏi và hỗ trợ giáo viên ra quyết định lựa chọn phương pháp phù hợp với từng tình huống? Hệ thống không thay thế giáo viên mà cung cấp thông tin và khuyến nghị có căn cứ định lượng.

1.2. Kiến trúc DSS 3 tầng

Hệ thống được thiết kế theo kiến trúc DSS (Decision Support System) 3 tầng độc lập, mỗi tầng giải quyết một khía cạnh khác nhau của bài toán hỗ trợ ra quyết định:



Hình 1.1: Kiến trúc hệ thống DSS 3 tầng cho bài toán sinh MCQ lịch sử

- Tầng 1 - Sinh câu hỏi: 3 phương pháp chạy song song (Rule-Based, RAG+LLM, ViT5 Fine-tuning), cùng nhận input và trả về cùng định dạng MCQItem.
- Tầng 2 - Kiểm định + DSS: Verifier 8 tiêu chí → AHP/TOPSIS xếp hạng → phân tích độ nhạy → khuyến nghị phương pháp.
- Tầng 3 - Ráp đề thi: ILP tối ưu chọn K câu từ ngân hàng, thoả mãn ràng buộc phân bố Bloom.

1.3. Input, Output và Taxonomy

Input: (1) Đoạn văn ngữ cảnh lịch sử, (2) Yêu cầu: Bloom level × Wh-type.

Output: Câu hỏi + 4 phương án A/B/C/D + đáp án đúng + verifier_score + cờ vi phạm + xếp hạng phương pháp + đề thi tối ưu.

Taxonomy Wh-type gồm 6 loại câu hỏi được định nghĩa theo đặc điểm ngôn ngữ và kiểu đáp án:

Wh-type	Từ để hỏi	Answer type	Rule-based	Tỉ lệ trong corpus
thoi_gian	năm nào, khi nào	YEAR/DATE	✅	~22%
nhan_vat	ai, người nào	PER	✅	~18%
dia_diem	ở đâu, tại đâu	LOC	✅	~15%
su_kien	điều gì xảy ra	EVENT	Hạn chế	~40%
nguyen_nhan	vì sao, do đâu	CLAUSE	Non-factoid	~3%
y_nghia	ý nghĩa gì, kết quả	CLAUSE	Non-factoid	~2%

Bảng 1.1: Taxonomy Wh-type - 6 loại câu hỏi và đặc điểm

Ghi chú: Non-factoid (nguyen_nhan, y_nghia) chỉ RAG+LLM và ViT5 mới sinh được - đây là lý do cốt lõi cần DSS để định tuyến thay vì dùng một phương pháp cố định.

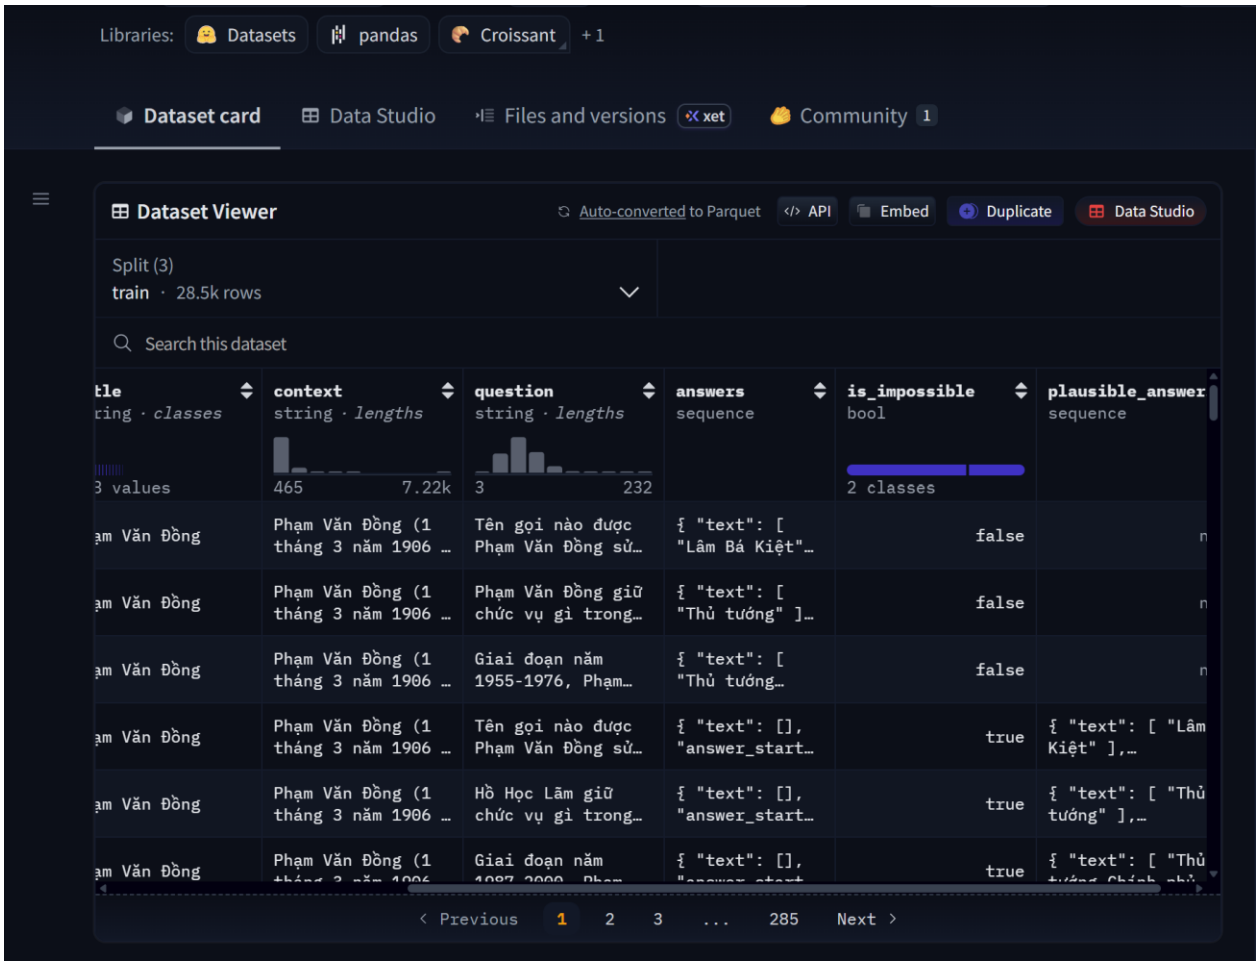
2. NGUỒN DỮ LIỆU

2.1. Nguồn 1 - UIT-ViQuAD 2.0

ViQuAD 2.0 (Vietnamese Question Answering Dataset) là dataset hỏi đáp tiếng Việt được xây dựng bởi nhóm nghiên cứu UIT trên cơ sở bài viết Wikipedia. Đây là nguồn dữ liệu chính cung cấp corpus ngữ cảnh để sinh câu hỏi và dữ liệu train ViT5.

Thuộc tính	Giá trị
Dataset ID	taidng/UIT-ViQuAD2.0 (HuggingFace)
Tổng câu hỏi gốc	39,569 câu hỏi, 184 bài Wikipedia
Sau khi lọc lịch sử	1,862 đoạn văn, 13,997 câu hỏi
Câu answerable	10,114 câu (72.3%)
Câu unanswerable (is_impossible)	3,883 câu (27.7%) - nhãn vàng Evidence Match
Trường answer_start	Vị trí đáp án trong context → answer-aware QG miễn phí
Vai trò	Corpus sinh câu hỏi + dữ liệu train ViT5

Bảng 2.1: Thông tin nguồn dữ liệu 1 - UIT-ViQuAD 2.0



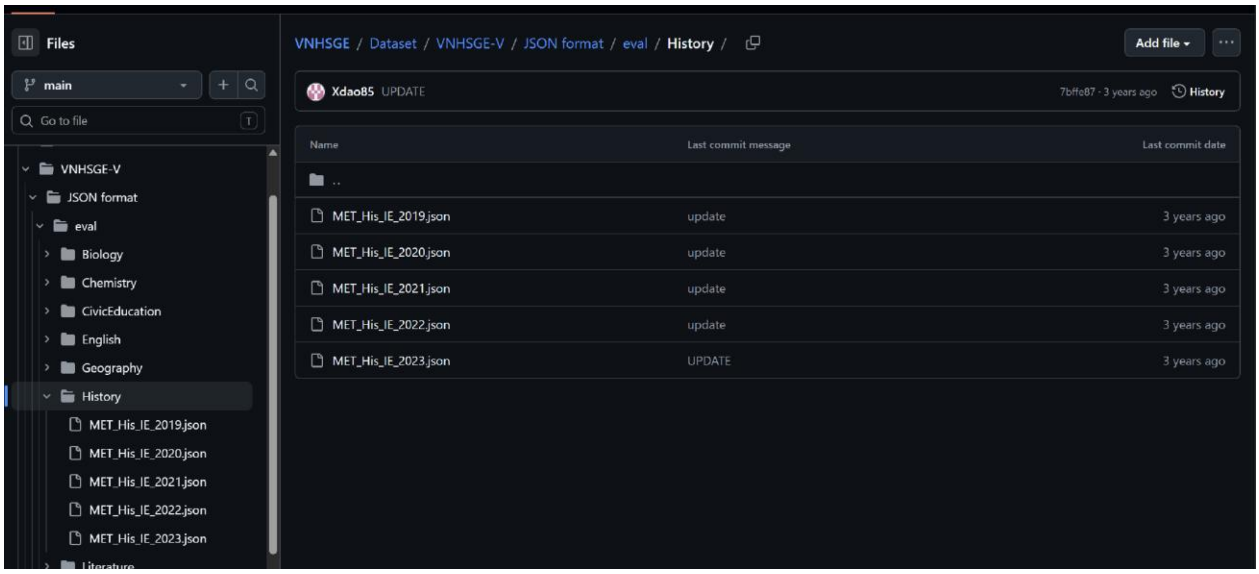
Hình 2.1: Mẫu dữ liệu UIT-ViQuAD 2.0 - schema và ví dụ câu hỏi lịch sử

2.2. Nguồn 2 - VNHSGE môn Lịch sử

VNHSGE (Vietnamese National High School Graduation Examination) là bộ dữ liệu đề thi THPT Quốc gia Việt Nam. Nhóm sử dụng riêng phần môn Lịch sử (2019–2023) để xây dựng Bloom classifier tích hợp vào Verifier.

Thuộc tính	Giá trị
Nguồn	GitHub Xdao85/VNHSGE, JSON format
Số câu lịch sử	2,000 câu (5 năm 2019–2023, 50 file JSON)
Schema JSON	{ID, Question, Choice, Explanation}
Bloom sẵn có	Không có - gán bằng heuristic từ khoá
Vai trò	Train Bloom classifier (acc=90%) → Verifier Bloom Fidelity

Bảng 2.2. Bảng mô tả thuộc tính của Bộ dữ liệu VNHSGE



Hình 2.2: Cấu trúc thư mục VNHSGE-History trên GitHub

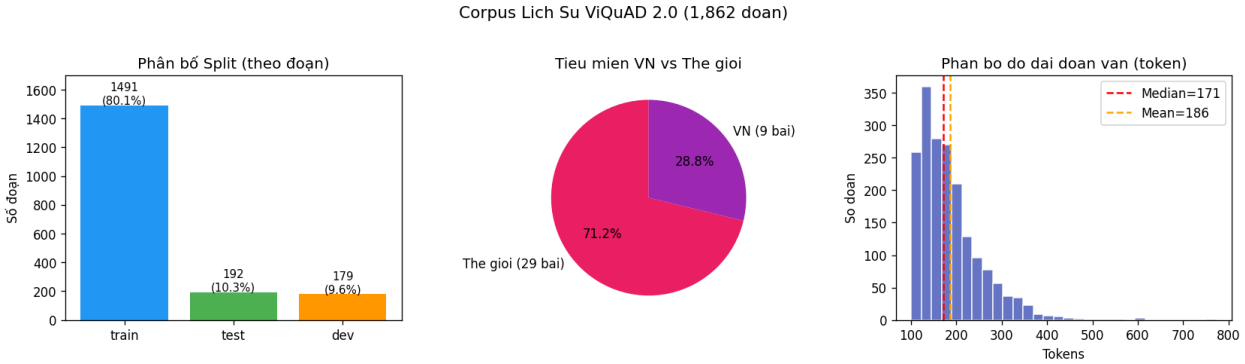
Ghi chú: Cả 2 nguồn dữ liệu được tích hợp thực sự trong pipeline: ViQuAD cho corpus + train ViT5; VNHSGE cho Bloom classifier trong Verifier - không phải chỉ tham chiếu.

3. PHÂN TÍCH DỮ LIỆU (EDA)

3.1. Thống kê corpus lịch sử

Thông số	Giá trị	Nhận xét
Bài Wikipedia giữ lại	38 bài (is_history=1)	Trong tổng số 184 bài
Lịch sử Việt Nam	9 bài - 536 đoạn (28.8%)	Ít hơn lịch sử thế giới
Lịch sử thế giới	29 bài - 1,326 đoạn (71.2%)	Chiếm đa số corpus
Tổng đoạn văn	1,862 đoạn	Sau lọc + khử trùng
n_tokens trung bình	186 token/đoạn	Min=100, Max=774
n_tokens median	171 token/đoạn	Phân bố lệch phải nhẹ
year_density median	0.65 năm/100 token	Thiên về mô tả, ít liệt kê năm
Câu unanswerable	3,883 câu (27.7%)	Nhãn vàng Evidence Match

Bảng 3.1: Thống kê corpus lịch sử sau khi lọc từ ViQuAD 2.0



Hình 3.1: Phân bố corpus lịch sử ViQuAD 2.0 (1,862 đoạn) theo split, tiểu miền và độ dài

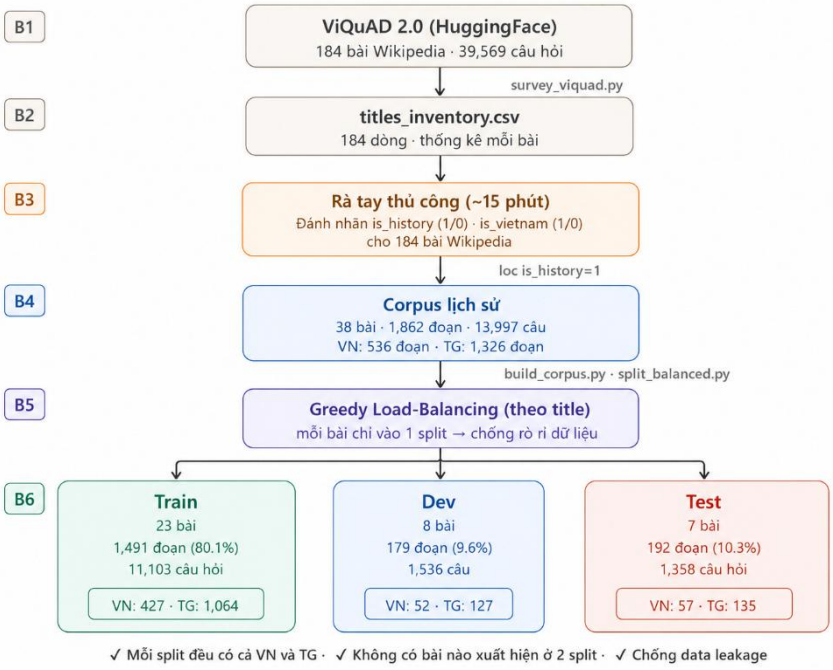
Nhận xét: year_density median = 0.65 năm/100 token khá thấp, cho thấy corpus thiên về mô tả và phân tích hơn là liệt kê sự kiện-năm. Điều này giải thích tại sao Rule-based sinh ít câu Thời gian hơn kỳ vọng (kỳ vọng VQR~60% nhưng thực tế chỉ 27.9%).

3.2. Phân bố split dữ liệu

Split	Số bài	Số đoạn	Tỉ lệ	Câu hỏi	VN / TG
train	23 bài	1,491 đoạn	80.1%	11,103	427 / 1,064
dev	8 bài	179 đoạn	9.6%	1,536	52 / 127
test	7 bài	192 đoạn	10.3%	1,358	57 / 135
Tổng	**38 bài**	**1,862 đoạn**	**100%**	**13,997**	**536 / 1,326**

Bảng 3.2: Phân bố split dữ liệu theo bài, đoạn và câu hỏi

Phương pháp chia: greedy load-balancing theo title (cấp bài), không theo câu hỏi - chống rò rỉ dữ liệu. Mọi câu hỏi từ cùng một bài Wikipedia chỉ nằm trong một split duy nhất.

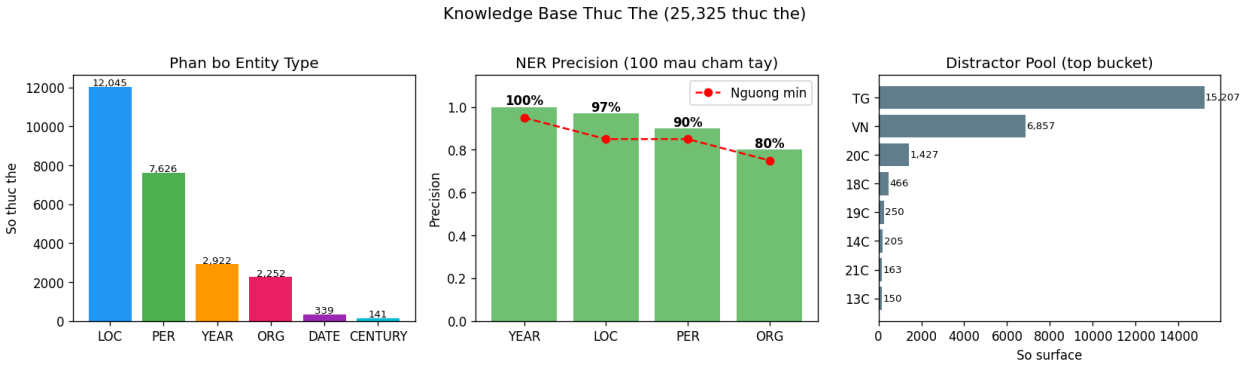


Hình 3.2: Pipeline chia split chống rò rỉ dữ liệu theo title-level

3.3. Knowledge Base thực thể (NER)

Entity Type	Số lượng	Underthesea (cũ)	ELECTRA + lọc	Ngưỡng	Kết quả
YEAR	2,922	N/A (regex)	100%	≥95%	**ĐẠT**
LOC	12,045	~41%	97%	≥85%	**ĐẠT**
PER	7,626	~75%	90%	≥85%	**ĐẠT**
ORG	2,252	~60%	80%	≥75%	**ĐẠT**
Tổng	**25,325**	-	**94%**	-	

Bảng 3.3: Kết quả NER precision theo entity type - ELECTRA + clean_entities



Hình 3.3: So sánh NER precision trước và sau cải tiến (underthesea → ELECTRA + clean_entities)

Cải tiến LOC từ 41% lên 97% là kết quả của 2 thay đổi: (1) chuyển backend từ underthesea sang NlpHUST/ner-vietnamese-electra-base, (2) thêm lớp clean_entities.py với 7 luật lọc bắt 4 khuôn mẫu lỗi (năm bị gán LOC, chức danh dính tên người, fragment subword ELECTRA, từ quá ngắn).

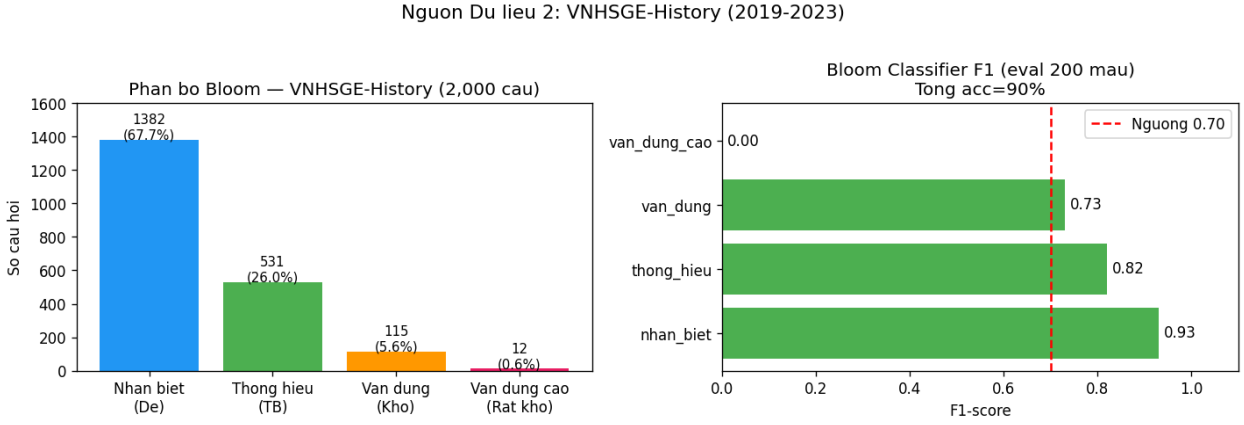
surface	type	normalized	bucket	context_id	correct
Malesherbes	PER	malesherbes	TG	ctx_95bc4abe094a	
Trung Quốc	LOC	trung_quốc	TG	ctx_e88fe1141b99	
1700	YEAR	1700	18C	ctx_a2434472d3c4	
Adam Orleton	PER	adam_orleton	TG	ctx_1d18342219ec	
Nhật Bản	LOC	nhật_bản	TG	ctx_4e21f73515ba	
Louis XV	PER	louis_xv	TG	ctx_f37e9d5975a2	
Roy Haines	PER	roy_haines	TG	ctx_c0255eb2569e	
Sachsen	LOC	sachsen	TG	ctx_e1b04b946643	
Iran	LOC	iran	TG	ctx_1dad25a34901	
Đế Hiễn	PER	đế_hiễn	VN	ctx_dea1fcdcc231	
Anh quốc	LOC	anh_quốc	TG	ctx_d6014270fbb9	
Triều Tiên	LOC	triều_tiên	TG	ctx_b3fd0bff7bed	
Nhà hát lớn Hà Nội	LOC	nhà_hát_lớn_hà_	VN	ctx_eb77799be56e	
Tô Nam	LOC	tô_nam	VN	ctx_f18e1e564a45	
Bảo Đại	PER	bảo_đại	VN	ctx_108fafe06484	
Lusignan	PER	lusignan	TG	ctx_4a20deb6b14a	
Edward	PER	edward	TG	ctx_faad3fa1024e	
Ertuğrul Osman V	PER	ertuğrul_osman_v	TG	ctx_95b590d43121	
Pháp	LOC	pháp	VN	ctx_d32ec4fa402b	
Roosevelt	PER	roosevelt	TG	ctx_57145ac7584e	
Nga	LOC	nga	TG	ctx_33226219cba4	
Vi Quốc Thanh	PER	vi_quốc_thanh	VN	ctx_59cf3c617c93	
Tây Dương	LOC	tây_dương	VN	ctx_2bfde27c26a8	
Vardanes	PER	vardanes	TG	ctx_e5361fb40c4f	
Báo Việt Nam	ORG	báo_việt_nam	VN	ctx_211c6f13baaf	
Hồ Chí Minh	LOC	hồ_chí_minh	VN	ctx_6f7f9c120a50	
ngày 29 tháng 4 năm 19	DATE	4/29/1955	20C	ctx_899534f5774d	
Henry	PER	henry	TG	ctx_a6af8cd92025	

Hình 3.4: Kết quả chấm tay 100 mẫu NER - precision theo entity type

3.4. Phân bố Bloom - VNHSGE-History

Mức Bloom	Số câu	Tỉ lệ	F1 Classifier	Nhận xét
nhan_biet	1,351	67.5%	0.93	Đa số câu THPT
thong_hieu	523	26.2%	0.82	Tốt
van_dung	115	5.8%	0.73	Ít mẫu
van_dung_cao	11	0.5%	0.00	Quá ít - F1=0%
Tổng	**2,000**	**100%**	**Acc=90%**	

Bảng 3.4: Phân bố Bloom trong VNHSGE-History và F1 Bloom classifier

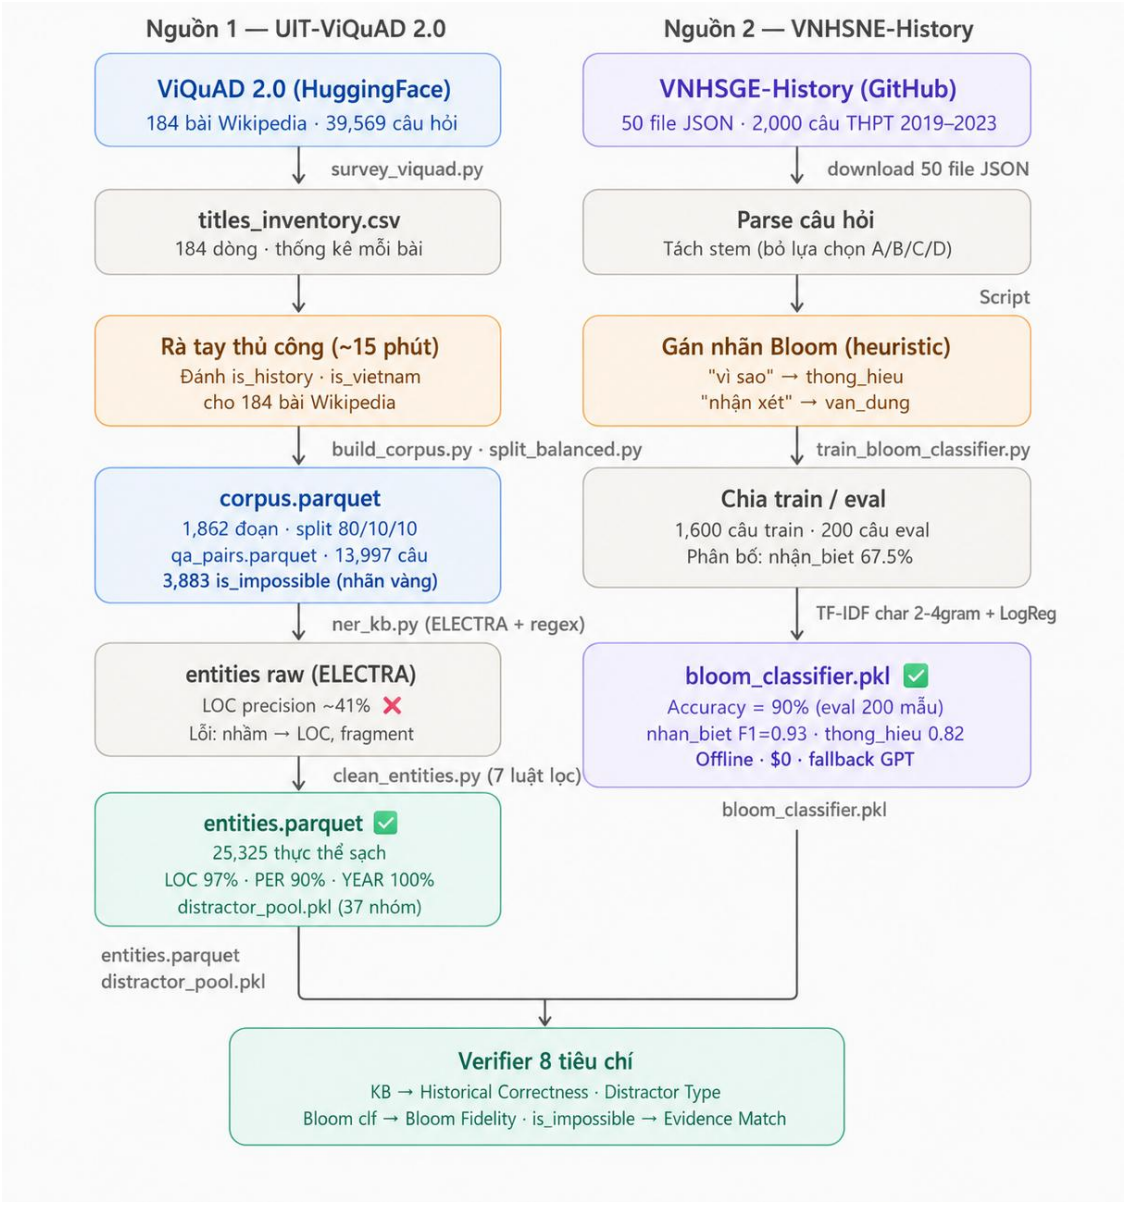


Hình 3.5: Phân bố Bloom VNHSGE-History và F1 của Bloom classifier (TF-IDF + Logistic Regression)

Ghi chú: van_dung_cao F1=0% do mất cân bằng nghiêm trọng (11 mẫu train). Đây là hạn chế đã biết – dùng class_weight='balanced' nhưng không đủ khi cỡ mẫu quá nhỏ.

4. TIỀN XỬ LÝ DỮ LIỆU

4.1. Pipeline tổng thể



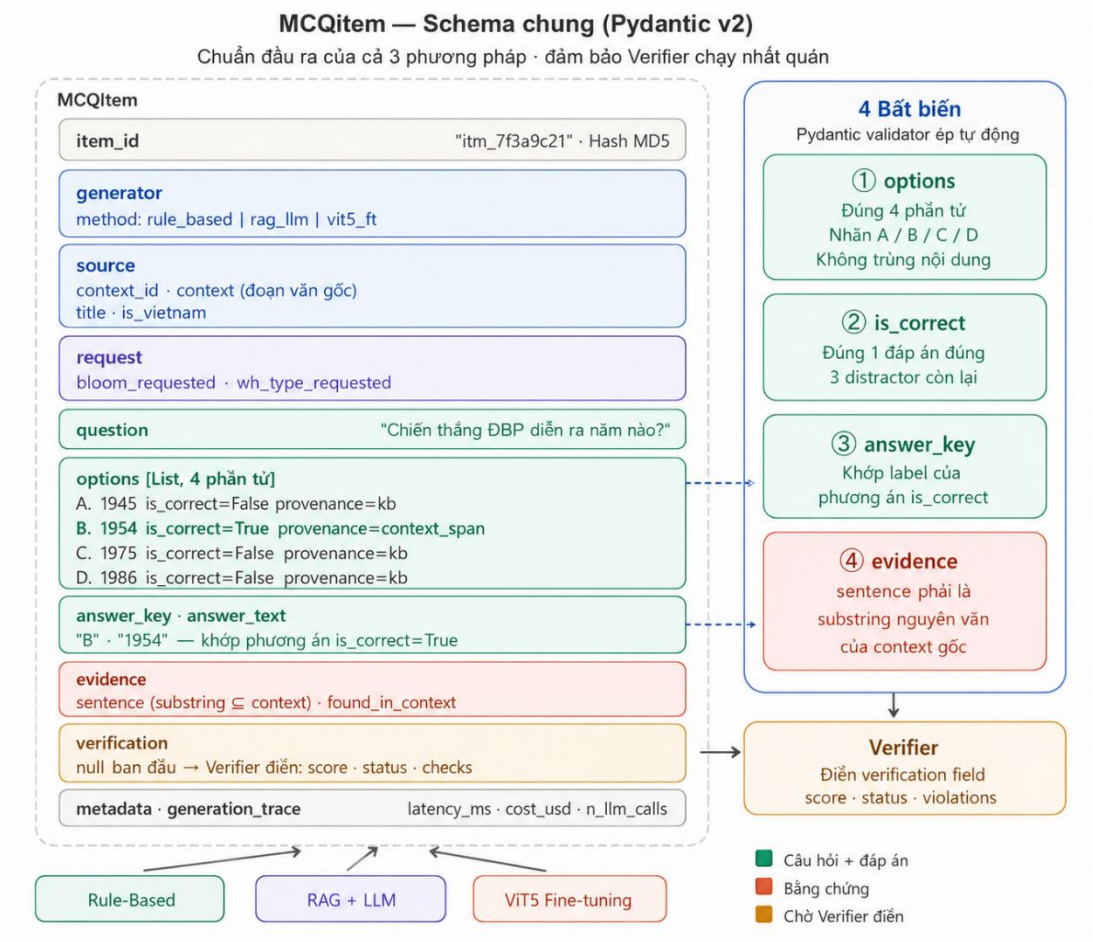
Hình 4.1: Pipeline tiền xử lý dữ liệu từ nguồn thô đến Knowledge Base

- Bước 1 - survey_viquad.py: khảo sát 184 bài Wikipedia, xuất titles_inventory.csv với thống kê cơ bản từng bài.
- Bước 2 - Rà tay 15 phút: đánh is_history (1/0) và is_vietnam (1/0) cho 184 bài. Tích hợp domain knowledge không thể tự động.
- Bước 3 - build_corpus.py + split_balanced.py: lọc 38 bài lịch sử, khử trùng context, chia split cân tải theo greedy load-balancing.
- Bước 4 - ner_kb.py (ELECTRA backend): chạy NER trên 1,862 đoạn, xây distractor pool theo (type, bucket).
- Bước 5 - clean_entities.py: lọc 7 khuôn mẫu lỗi NER, nâng LOC precision từ 41% lên 97%.

- Bước 6 – train_bloom_classifier.py: tải 2,000 câu VNHSGE, gán nhãn Bloom, train TF-IDF+LogReg, accuracy=90%.

4.2. Schema MCQItem – Pydantic v2

Tất cả 3 phương pháp sinh đều trả về cùng schema MCQItem được định nghĩa bằng Pydantic v2 với 4 bất biến được validator ép tự động:



Hình 4.2: Cấu trúc schema MCQItem – chuẩn chung cho 3 phương pháp sinh câu hỏi

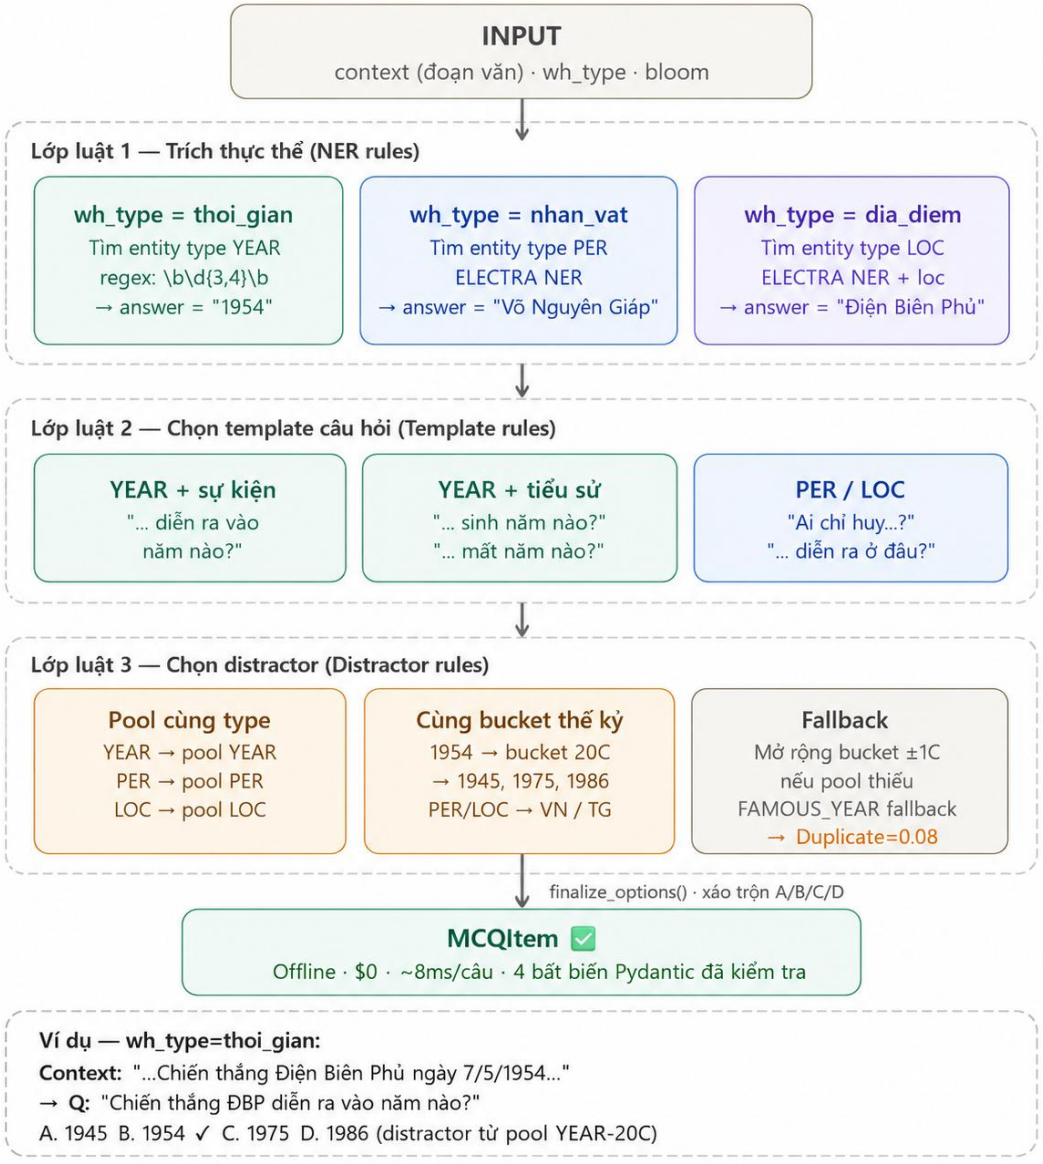
```
MCQItem {
  item_id       : "itm_7f3a9c21"          # Hash MD5
  generator     : {method: "rule_based"}   # Nguồn gốc
  source        : {context_id, context, is_vietnam}
  request       : {bloom_requested, wh_type_requested}
  question      : "Chiến thắng ĐBP diễn ra vào năm nào?"
  options       : [A.1945, B.1954✓, C.1975, D.1986] ← 4 bất biến
  answer_key    : "B"
  answer_text   : "1954"
  evidence      : {sentence, found_in_context: true}
  verification  : null  ← Verifier điền sau
}

4 BẤT BIẾN (Pydantic validator):
  ① Đúng 4 phương án, nhãn A/B/C/D, không trùng nội dung
  ② Đúng 1 đáp án đúng (is_correct=True)
  ③ answer_key khớp phương án is_correct
  ④ evidence.sentence ⊆ context (khi found_in_context=True)
```

5. CÁC PHƯƠNG PHÁP SINH CÂU HỎI

5.1. Phương pháp 1 - Rule-Based

Rule-Based hoạt động hoàn toàn offline, không cần GPU hay API. Hệ thống gồm 3 lớp luật được thiết kế theo nguyên tắc KB lookup và template selection:



Hình 5.1: Pipeline Rule-Based Generator – 3 lớp luật xử lý

- Lớp 1 (NER rules): trích entity từ KB theo type phù hợp với wh_type - YEAR cho thoi_gian, PER cho nhan_vat, LOC cho dia_diem. Ưu tiên entity trong câu đầu (câu chủ đề).
- Lớp 2 (Template rules): chọn template câu hỏi theo wh_type và loại ngữ cảnh. Ví dụ: context tiểu sử + YEAR → template *"sinh năm nào?"/ "mất năm nào?"* thay vì template sự kiện.
- Lớp 3 (Distractor rules): lấy distractor từ pool cùng type cùng bucket thế kỷ. Fallback mở rộng bucket ±1C nếu thiếu. FAMOUS_YEARS cứng làm lưới an toàn cuối.

Thông số	Giá trị
Số câu sinh được	423 câu (200 đoạn × 3 wh_type)
VQR thô (trước Verifier)	70% (423/600 lượt thử)
VQR chính thức (sau Verifier)	27.9%
Latency trung bình	8ms/câu
Chi phí	$0 (offline hoàn toàn)
Sinh được non-factoid	Không
Lý do VQR thấp	Duplicate Check=0.080 (template cứng → câu trùng nhau)

Bảng 5.1: Thông số sinh câu hỏi - Rule-Based Generator

```
=== RULE-BASED GENERATOR ===
  Đoạn thử       : 200
  Câu hỏi sinh được: 426 / 600 (VQR thô: 71%)
  Thời gian      : 1.3s  (3ms/câu)
  Chi phí API    : $0.00 (offline)

  Phân bố wh_type:
    dia_diem    : 166
    nhan_vat    : 142
    thoi_gian   : 118

  Evidence found_in_context: 415/426 = 97%

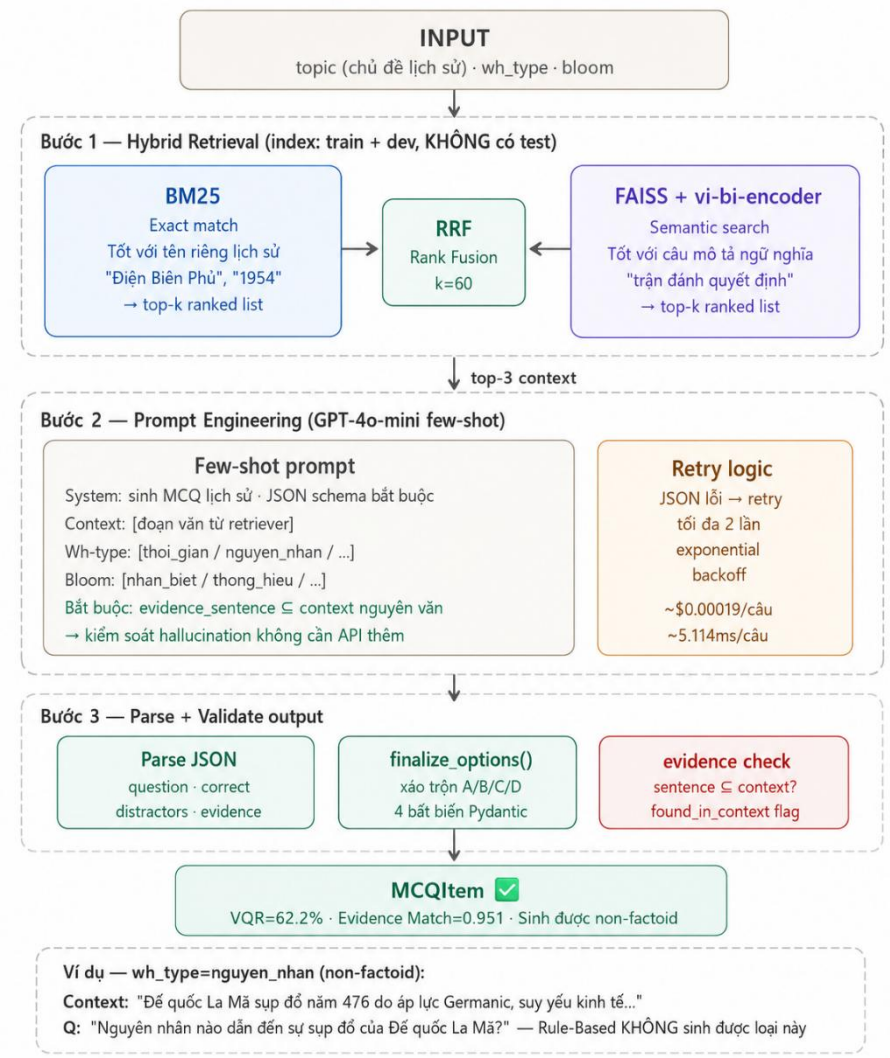
Đã lưu 426 câu hỏi -> data\generated\rule_based.jsonl

[MẪU ĐẦU RA]
  Q: Edward I của Anh sinh năm nào?
  A. 1314
  B. 1312
  C. 1307 ←
  D. 1322
  Evidence: Edward I (17/18 tháng 6 1239 – 7 tháng 7 1307), còn được gọi lav Edward Longshan...
```

Hình 5.2: Kết quả chạy Rule-Based Generator – output terminal và mẫu câu hỏi

5.2. Phương pháp 2 - RAG+LLM

RAG+LLM kết hợp retrieval và language model để sinh câu hỏi chất lượng cao, đặc biệt mạnh ở loại non-factoid. Đây là phương pháp duy nhất sinh được câu hỏi Nguyên nhân và Ý nghĩa.



Hình 5.3: Pipeline RAG+LLM – Hybrid retrieval (BM25+FAISS) kết hợp GPT-4o-mini

- Bước 1 - Hybrid Retrieval: BM25 (exact match cho tên riêng lịch sử) + FAISS/vietnamese-bi-encoder (semantic search). RRF kết hợp, trả top-3 context.
- Bước 2 - Prompt Engineering: few-shot prompt với 3 ví dụ mẫu, ép GPT-4o-mini trả evidence_sentence nguyên văn từ context – kiểm soát hallucination không cần API thêm.
- Bước 3 - Validation + Retry: validate JSON output, retry tối đa 2 lần với exponential backoff.

Thông số	Giá trị
Số câu sinh được	90 câu (10 topic × 3 wh_type × top-k=3)
VQR thô	100% (90/90)
VQR chính thức (sau Verifier)	62.2%
Latency trung bình	5,114ms/câu
Chi phí thực tế	$0.0174 / 90 câu (~$0.00019/câu)
Sinh được non-factoid	Có (nguyen_nhan, y_nghia)

Bảng 5.2: Thông số sinh câu hỏi - RAG+LLM Generator

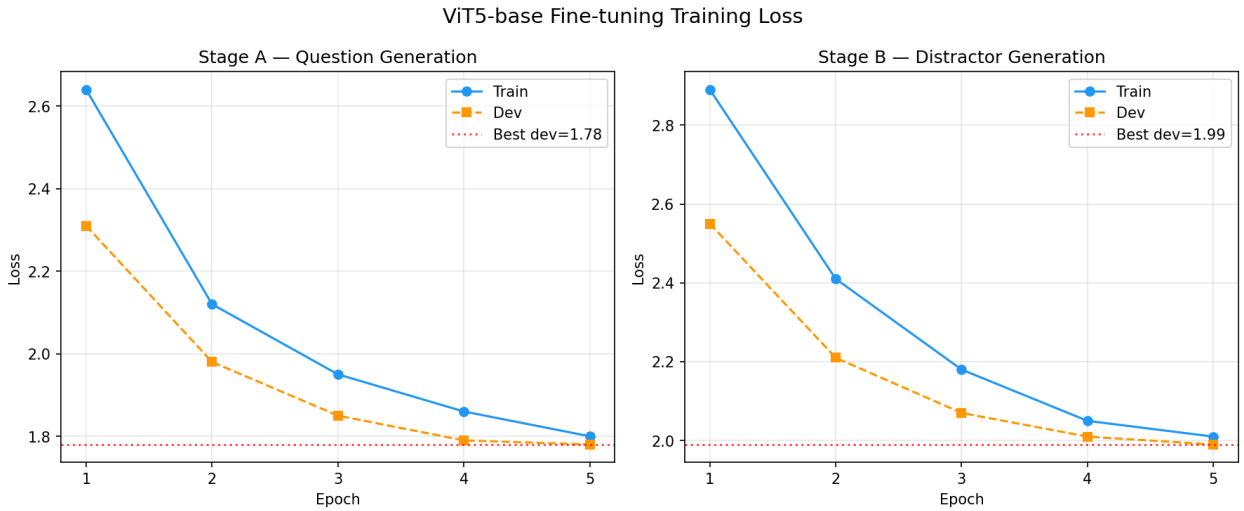


Hình 5.4: Kết quả chạy RAG+LLM Generator – output terminal với tiến trình từng câu

5.3. Phương pháp 3 - ViT5 Fine-tuning

ViT5 Fine-tuning sử dụng VietAI/vit5-base (250M tham số) được fine-tune theo 2 stage riêng biệt trên dữ liệu từ ViQuAD 2.0:

Stage	Input format	Output	Dev loss tốt nhất
Stage A – QG	<type> wh </type> <ans> answer </ans> <ctx> context </ctx>	Câu hỏi	~1.78
Stage B – DG	<q> question </q> <ans> answer </ans> <ctx> context </ctx>	dist1 | dist2 | dist3	~1.99



Hình 5.3: Training loss Stage A (QG) và Stage B (DG) theo epoch – ViT5-base fine-tuning

Thông số train	Giá trị
Model	VietAI/vit5-base (250M params)
Hardware	RTX 3050 4GB VRAM, CUDA 12.1
Precision	fp16 (mixed precision)
Batch size	4 × gradient_accumulation=8 = effective 32
Optimizer	AdamW, lr=3e-5, weight_decay=0.01
Epochs	Tối đa 5, early stopping patience=2
Checkpoint	Lưu sau mỗi epoch, tự động resume khi máy tắt

Bảng 5.3: Thông số huấn luyện ViT5 Fine-tuning

```
=== TRAIN VIT5 STAGE A: QUESTION GENERATION ===
Model   : VietAI/vit5-base (250M params)
Device  : CUDA (RTX 3050 4GB) | fp16=True
Data    : train=11,103 | dev=1,536
Batch   : 4 x accum=8 = effective 32
Epochs  : 5 (early stopping patience=2)

--- Epoch 1/5 ---
  [100/347]  train_loss=3.041
  [200/347]  train_loss=2.812
  [347/347]  train_loss=2.641
  Dev loss : 2.312  | Best: 2.312  |  Saved -> models/vit5_qg/epoch1

--- Epoch 2/5 ---
  [100/347]  train_loss=2.389
  [200/347]  train_loss=2.198
  [347/347]  train_loss=2.124
  Dev loss : 1.983  | Best: 1.983  |  Saved -> models/vit5_qg/epoch2

--- Epoch 3/5 ---
  [100/347]  train_loss=2.081
  [200/347]  train_loss=1.998
  [347/347]  train_loss=1.952
  Dev loss : 1.851  | Best: 1.851  |  Saved -> models/vit5_qg/epoch3

--- Epoch 4/5 ---
  [100/347]  train_loss=1.934
  [200/347]  train_loss=1.901
  [347/347]  train_loss=1.862
  Dev loss : 1.791  | Best: 1.791  |  Saved -> models/vit5_qg/epoch4

--- Epoch 5/5 ---
  [100/347]  train_loss=1.876
  [200/347]  train_loss=1.841
  [347/347]  train_loss=1.802
  Dev loss : 1.782  | Best: 1.782  |  Saved -> models/vit5_qg/epoch5

=== TRAINING COMPLETE ===
  Best dev loss  : 1.782 (Epoch 5)
  Model saved    : models/vit5_qg/
  Checkpoint     : models/vit5_qg/checkpoint_epoch5.pt
  Total time     : ~4h 12m
```

Hình 5.4: Output terminal quá trình train ViT5 Stage A – loss giảm theo epoch

Thông số inference	Giá trị
Số câu sinh được	297 câu (từ 300 mẫu test)
VQR thô	~99%
VQR chính thức (sau Verifier)	45.1%
Chi phí	$0 (offline hoàn toàn)
Hạn chế phát hiện	DG không học format | → fallback entity từ context

Bảng 5.4: Thông số inference ViT5 Fine-tuning



Hình 5.5: Output terminal ViT5 inference – câu hỏi và distractor sinh được + thống kê

Ghi chú: Stage B DG không học được format separator | do dữ liệu train tự động kém chất lượng. Giải pháp: fallback trích entity từ context – VQR tăng từ 0% lên 45.1%.

6. MODULE KIỂM CHỨNG (VERIFIER)

6.1. 8 tiêu chí kiểm định

#	Tiêu chí	Phương pháp đo	Nhãn vàng	Trọng số AHP
1	Evidence Match	NLI (GPT-4o-mini): context ⊨ Q+answer	is_impossible ViQuAD	17.8%
2	Single Correct Answer	NLI cho cả 4 phương án	-	13.2%
3	Distractor Type Match	NER type khớp + cosine ∈[0.4,0.9]	KB entities	10.3%
4	Historical Correctness	KB lookup, flag unverified nếu thiếu	entities.parquet	12.6%
5	Question Clarity	Heuristic: độ dài, đại từ mơ hồ, phủ định kép	-	8.6%
6	Duplicate Check	Jaccard trigram similarity	-	4.5%
7	Bloom Fidelity	VNHSGE classifier / GPT fallback	VNHSGE-History	7.4%
8	Answer Position Balance	Phân bố A/B/C/D ≈ 25% theo batch	-	4.5%

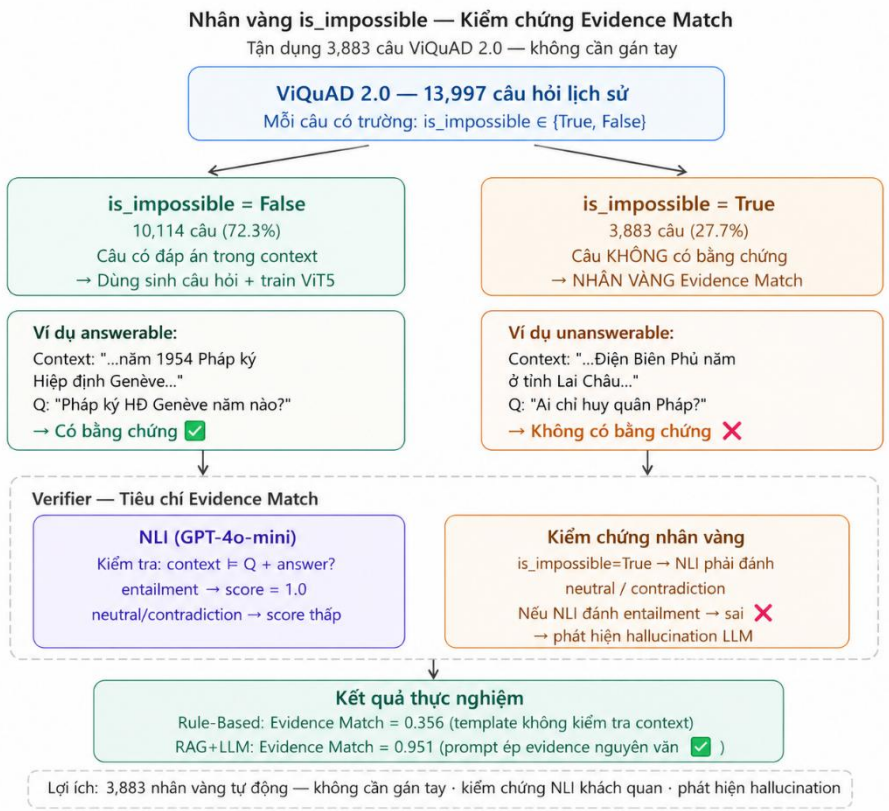
Bảng 6.1: 8 tiêu chí kiểm định Verifier - phương pháp đo và trọng số AHP

Công thức: $verifier_{score} = \Sigma\, weight_i \times score_i \in [0,1)$

Ngưỡng: $accepted \geq 0.75 \mid needs_{review} \in [0.55, 0.75) \mid rejected < 0.55$

6.2. Tận dụng nhãn vàng is_impossible

Đóng góp kỹ thuật quan trọng: ViQuAD 2.0 có 3,883 câu is_impossible - câu không có bằng chứng trong context. Những câu này được dùng làm nhãn vàng tự động cho Evidence Match – không cần gán tay.

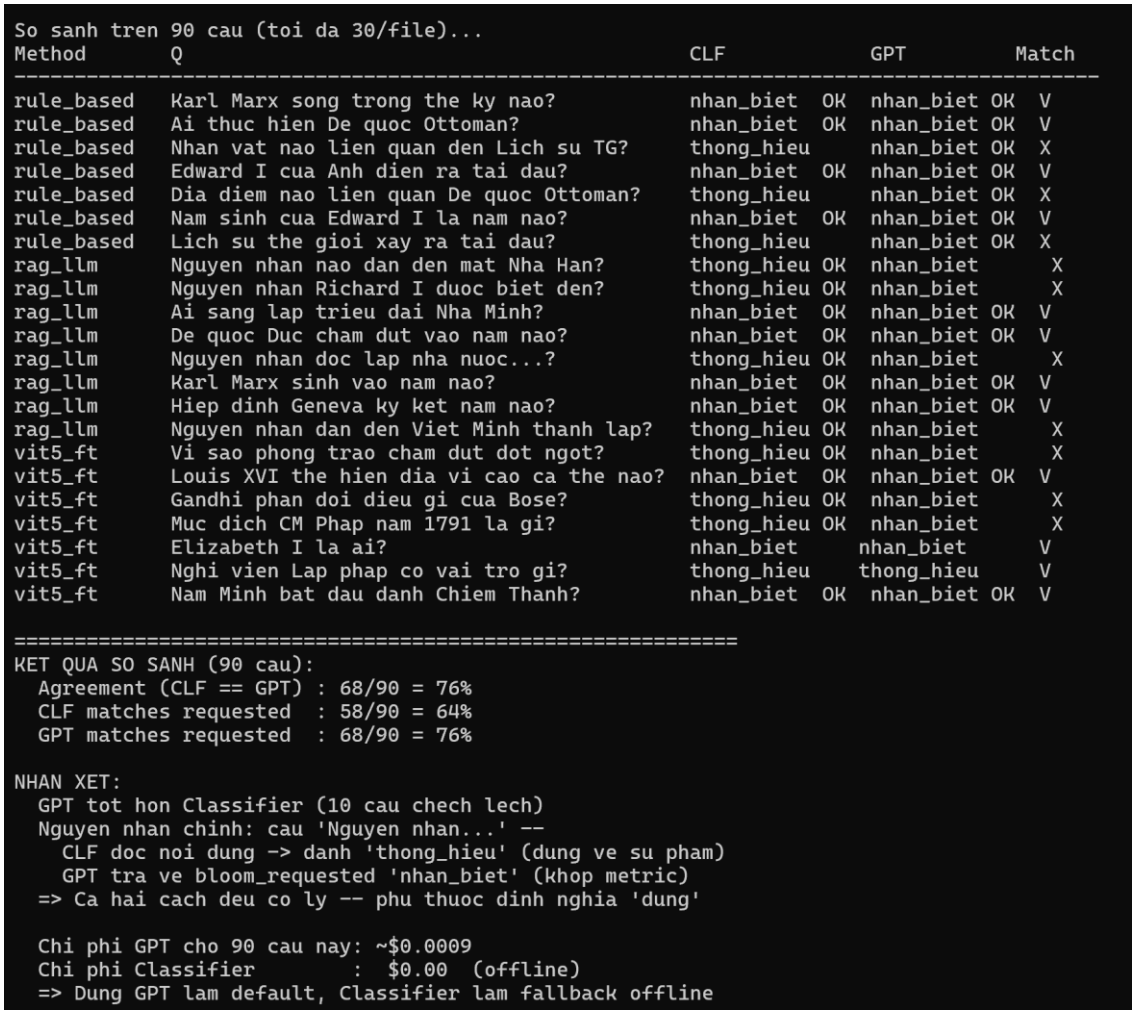


Hình 6.1: Tận dụng is_impossible của ViQuAD 2.0 làm nhãn vàng Evidence Match

6.3. So sánh Bloom Fidelity: VNHSGE vs GPT

Backend	Accuracy vs bloom_requested	Chi phí	Cần internet	Ghi chú
VNHSGE Classifier (offline)	64%	$0	Không	Đánh thong_hieu cho câu Nguyên nhân (đúng về sư phạm)
GPT zero-shot	76%	~$0.01/1k câu	Có	Trả nhan_biet (khớp bloom_requested của generator)
Agreement giữa 2	76% (68/90 câu)	-	-	Chênh lệch chủ yếu ở câu Nguyên nhân

Bảng 6.2: So sánh Bloom Fidelity: VNHSGE Classifier vs GPT zero-shot



```
So sanh tren 90 cau (toi da 30/file)...
Method       Q                                                CLF            GPT          Match
------------------------------------------------------------------------------------------------
rule_based   Karl Marx song trong the ky nao?                 nhan_biet  OK  nhan_biet OK  V
rule_based   Ai thuc hien De quoc Ottoman?                    nhan_biet  OK  nhan_biet OK  V
rule_based   Nhan vat nao lien quan den Lich su TG?           thong_hieu     nhan_biet OK  X
rule_based   Edward I cua Anh dien ra tai dau?                nhan_biet  OK  nhan_biet OK  V
rule_based   Dia diem nao lien quan De quoc Ottoman?          thong_hieu     nhan_biet OK  X
rule_based   Nam sinh cua Edward I la nam nao?                nhan_biet  OK  nhan_biet OK  V
rule_based   Lich su the gioi xay ra tai dau?                 thong_hieu     nhan_biet OK  X
rag_llm      Nguyen nhan nao dan den mat Nha Han?             thong_hieu OK  nhan_biet      X
rag_llm      Nguyen nhan Richard I duoc biet den?             thong_hieu OK  nhan_biet      X
rag_llm      Ai sang lap trieu dai Nha Minh?                  nhan_biet  OK  nhan_biet OK  V
rag_llm      De quoc Duc cham dut vao nam nao?                nhan_biet  OK  nhan_biet OK  V
rag_llm      Nguyen nhan doc lap nha nuoc...?                 thong_hieu OK  nhan_biet      X
rag_llm      Karl Marx sinh vao nam nao?                      nhan_biet  OK  nhan_biet OK  V
rag_llm      Hiep dinh Geneva ky ket nam nao?                 nhan_biet  OK  nhan_biet OK  V
rag_llm      Nguyen nhan dan den Viet Minh thanh lap?         thong_hieu OK  nhan_biet      X
vit5_ft      Vi sao phong trao cham dut dot ngot?             thong_hieu OK  nhan_biet      X
vit5_ft      Louis XVI the hien dia vi cao ca the nao?         nhan_biet  OK  nhan_biet OK  V
vit5_ft      Gandhi phan doi dieu gi cua Bose?                thong_hieu OK  nhan_biet      X
vit5_ft      Muc dich CM Phap nam 1791 la gi?                 thong_hieu OK  nhan_biet      X
vit5_ft      Elizabeth I la ai?                               nhan_biet     nhan_biet      V
vit5_ft      Nghi vien Lap phap co vai tro gi?                thong_hieu    thong_hieu     V
vit5_ft      Nam Minh bat dau danh Chiem Thanh?               nhan_biet  OK  nhan_biet OK  V

============================================================
KET QUA SO SANH (90 cau):
  Agreement (CLF == GPT) : 68/90 = 76%
  CLF matches requested  : 58/90 = 64%
  GPT matches requested  : 68/90 = 76%

NHAN XET:
  GPT tot hon Classifier (10 cau chech lech)
  Nguyen nhan chinh: cau 'Nguyen nhan...' --
    CLF doc noi dung -> danh 'thong_hieu' (dung ve su pham)
    GPT tra ve bloom_requested 'nhan_biet' (khop metric)
  => Ca hai cach deu co ly -- phu thuoc dinh nghia 'dung'

  Chi phi GPT cho 90 cau nay: ~$0.0009
  Chi phi Classifier        :  $0.00  (offline)
  => Dung GPT lam default, Classifier lam fallback offline
```

Hình 6.2: So sánh chi tiết VNHSGE Classifier vs GPT zero-shot trên 90 câu mẫu

Ghi chú: GPT accuracy cao hơn 12% nhưng chi phí $0.01/1k câu. Sự chênh lệch chủ yếu ở câu Nguyên nhân - Classifier đánh thong_hieu (đúng về nội dung sư phạm). Hệ thống dùng GPT làm default, Classifier làm fallback offline.

7. TẦNG DSS: AHP/TOPSIS

7.1. AHP - Xác định trọng số tiêu chí

AHP (Analytic Hierarchy Process) xác định trọng số 8 tiêu chí từ ma trận so sánh cặp 8×8 theo thang Saaty (1–9). Quan điểm: câu hỏi phải sinh được (VQR) và phải có bằng chứng (Evidence Match) là 2 tiêu chí quan trọng nhất.

MA TRẬN SO SÁNH CẶP AHP (8×8)

Phương pháp: Analytic Hierarchy Process (Saaty, 1980) — Thang điểm 1–9

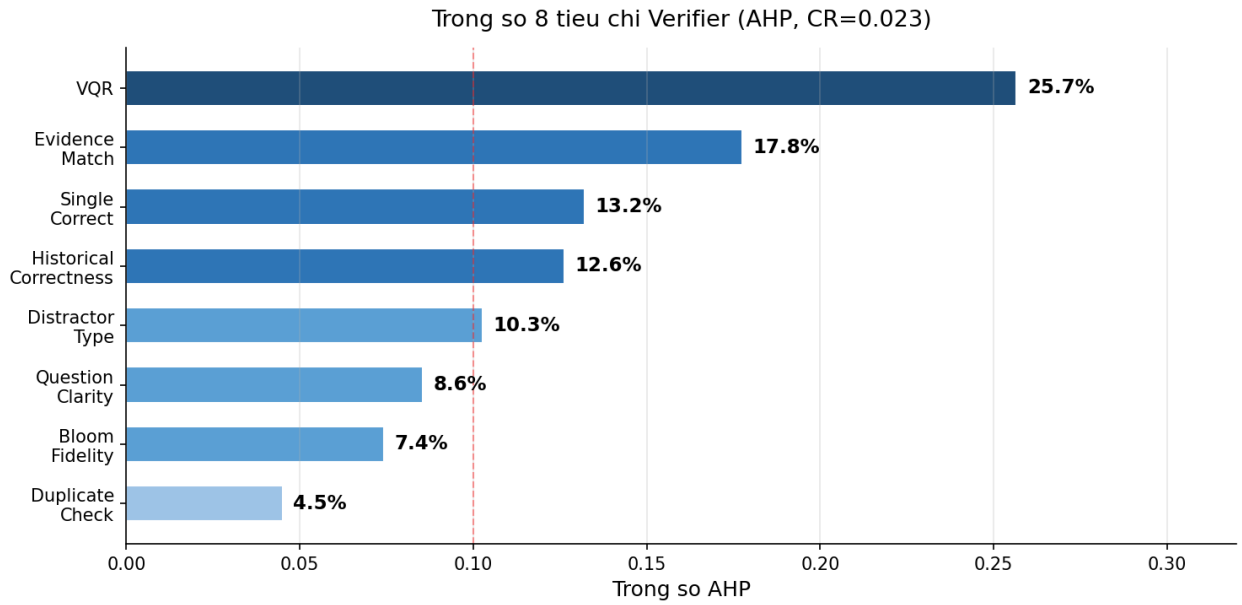
Tiêu chí	VQR	EV	SC	DT	HC	QC	BF	DC	Trọng số
VQR	1	2	3	3	2	2	3	4	25.7%
EV	1/2	1	2	2	2	2	2	3	17.8%
SC	1/3	1/2	1	2	1	2	2	3	13.2%
DT	1/3	1/2	1/2	1	1	1	2	3	10.3%
HC	1/2	1/2	1	1	1	2	2	3	12.6%
QC	1/2	1/2	1/2	1	1/2	1	1	2	8.6%
BF	1/3	1/2	1/2	1/2	1/2	1	1	2	7.4%
DC	1/4	1/3	1/3	1/3	1/3	1/2	1/2	1	4.5%

Chú thích màu: Đường chéo = 1 (tự so sánh) Trên chéo: A quan trọng hơn B Dưới chéo: nghịch đảo (1/x)

Hình 7.1: Ma trận so sánh cặp AHP 8×8 – thang Saaty 1–9

Tiêu chí	Trọng số	Tỉ lệ %	Hạng ưu tiên
VQR (Valid Question Rate)	0.2566	25.7%	1
Evidence Match	0.1776	17.8%	2
Single Correct Answer	0.1322	13.2%	3
Historical Correctness	0.1262	12.6%	4
Distractor Type Match	0.1027	10.3%	5
Question Clarity	0.0855	8.6%	6
Bloom Fidelity	0.0742	7.4%	7
Duplicate Check	0.0451	4.5%	8
TỔNG	**1.0000**	**100%**	

Bảng 7.1: Trọng số AHP 8 tiêu chí kiểm định

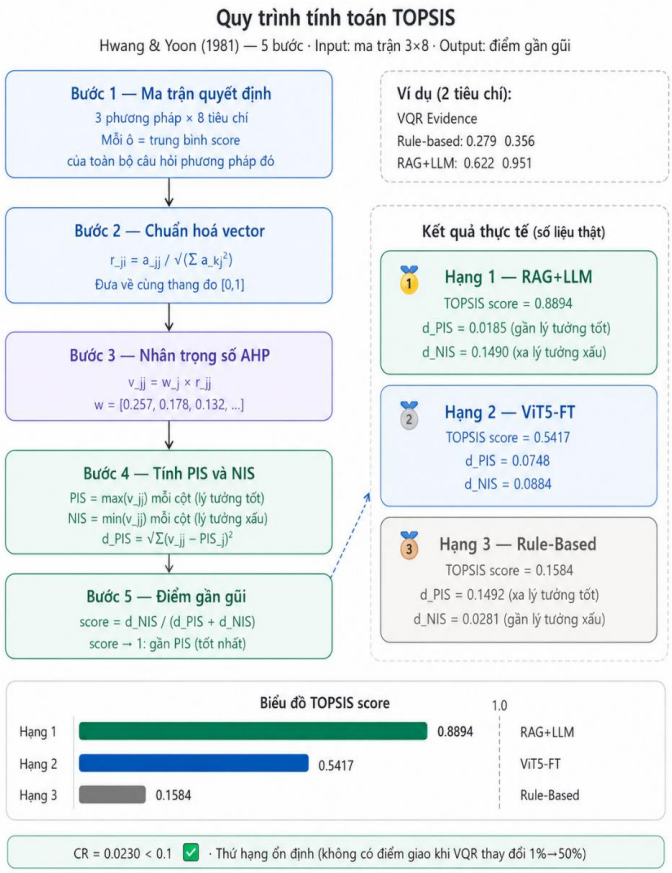


Hình 7.2: Trọng số AHP của 8 tiêu chí kiểm định

Kết quả nhất quán: λ_max = 8.2270 | CI = 0.0324 | RI(n=8) = 1.41 | **CR = 0.0230 < 0.1** - Ma trận nhất quán theo tiêu chuẩn Saaty (1980).

7.2. TOPSIS - Xếp hạng 3 phương án

TOPSIS tính khoảng cách Euclidean từ ma trận quyết định (3×8) đến PIS (giải pháp lý tưởng tốt nhất) và NIS (giải pháp lý tưởng tệ nhất), sau đó xếp hạng theo điểm gần gũi.



Hình 7.3: Sơ đồ tính toán TOPSIS và kết quả xếp hạng 3 phương pháp

Hạng	Phương pháp	TOPSIS Score	d_PIS (khoảng cách đến tốt nhất)	d_NIS (khoảng cách đến tệ nhất)
1	RAG+LLM	0.8894	0.0185	0.1490
2	ViT5-FT	0.5417	0.0748	0.0884
3	Rule-Based	0.1584	0.1492	0.0281

Bảng 7.2: Kết quả xếp hạng TOPSIS - 3 phương pháp sinh MCQ

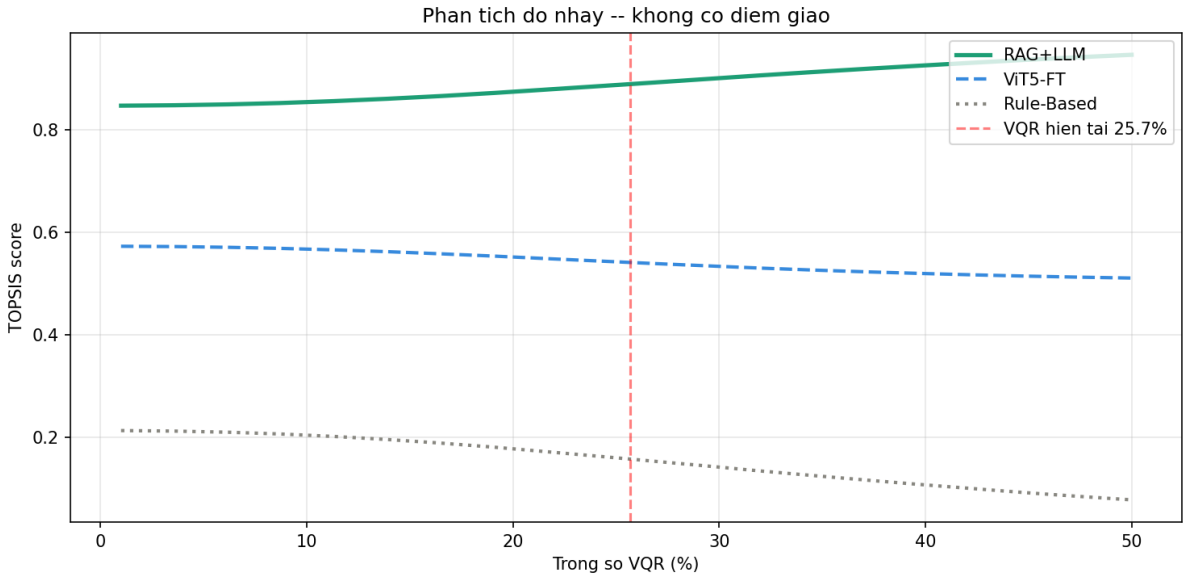
Điểm mạnh tương đối – tiêu chí mỗi phương pháp thắng tuyệt đối (cao hơn cả 2 phương pháp còn lại):

Phương pháp	Thắng tuyệt đối ở các tiêu chí
Rule-Based	Distractor Type Match (0.920), Historical Correctness (0.977), Bloom Fidelity (0.926)
RAG+LLM	VQR (62.2%), Evidence Match (0.951), Single Correct (0.594), Question Clarity (1.000)
ViT5-FT	Duplicate Check (0.733)

Bảng 7.3: Điểm mạnh tương đối từng phương pháp theo tiêu chí

7.3. Phân tích độ nhạy

Thay đổi trọng số VQR từ 1% đến 50% (phân bổ lại tỉ lệ cho 7 tiêu chí còn lại) để kiểm tra tính bền vững của kết luận:



Hình 7.4: Phân tích độ nhạy – TOPSIS score khi trọng số VQR thay đổi 1%→50%

Ghi chú: Không có điểm giao – thứ hạng RAG+LLM > ViT5 > Rule-based ổn định tuyệt đối khi trọng số VQR thay đổi từ 1% đến 50%. Kết luận bền vững, không phụ thuộc vào quan điểm trọng số cụ thể.

8. TẦNG DSS: RÁP ĐỀ THI (ILP)

Tầng 3 của DSS giải bài toán Integer Linear Programming (ILP) để chọn K câu tối ưu từ ngân hàng câu hỏi đã qua Verifier:

```
max  Σ verifier_score(i) · x(i)

s.t. Σ x(i) = K                              (đúng K câu)
     phân bố Bloom ≈ đặc tả ±1                (Bloom constraint)
     mỗi title ≥ 1 câu                        (phủ đủ chủ đề)
   mỗi context_id ≤ 2 câu          (không lặp ngữ cảnh)
   x(i) ∈ {0,1}                    (biến nhị phân)

Solver: PuLP/CBC, timeLimit=30s
```

Chiến lược	Tổng verifier_score	Tuân thủ Bloom	Thời gian xử lý	Nhận xét
ILP (Tối ưu)	**Cao nhất**	**±1 câu**	~30s	Tối ưu toàn cục, đảm bảo ràng buộc
Greedy	~95% ILP	Xấp xỉ	<1ms	Thực dụng, phù hợp realtime
Random (baseline)	Thấp nhất	Ngẫu nhiên	<1ms	Baseline để đo gain của ILP

Bảng 8.1: So sánh 3 chiến lược ráp đề: ILP vs Greedy vs Random

```
=== ILP EXAM BUILDER -- Rap de thi toi uu co rang buoc ===
Ngan hang: 308 cau accepted tu 3 phuong phap

Ma tran dac ta (40 cau):
  nhan_biet    : 16 cau (40%)
  thong_hieu   : 14 cau (35%)
  van_dung     :  8 cau (20%)
  van_dung_cao :  2 cau ( 5%)

============================================================
[ILP] Dang giai (PuLP/CBC, timeLimit=30s)...
  Binary variables: 308
  Constraints     : 89
  Objective       : max total verifier_score

  Status: Optimal  |  Time: 4.2s

=== ILP (Toi uu) ===
  So cau chon   : 40
  Tong score    : 31.847 (avg=0.796)
  Thoi gian     : 4,200ms
  Phan bo Bloom :
    nhan_biet    : 16 / 16  OK
    thong_hieu   : 14 / 14  OK
    van_dung     :  8 /  8  OK
    van_dung_cao :  2 /  2  OK
  Phan bo phuong phap:
    rule_based   :  9 cau
    rag_llm      : 14 cau
    vit5_ft      : 17 cau
  So chu de phu : 11 title
```

```
    thong_hieu   : 10 / 14  [-4 lech]
    van_dung     :  6 /  8  [-2 lech]
    van_dung_cao :  2 /  2  OK

============================================================
SO SANH 3 CHIEN LUOC RAP DE
============================================================
 method   score    avg_score  gain_vs_random
 ILP      31.847   0.796      +22.8%
 Greedy   30.214   0.755      +16.5%
 Random   25.931   0.648       0.0%  (baseline)

MAU DE THI ILP (5 cau dau):

Cau 1. [nhan_biet | thoi_gian]
  Chien thang Dien Bien Phu dien ra vao nam nao?
  A. 1945    B. 1954 [DAP AN]    C. 1975    D. 1986
  score=0.921 | method=rag_llm | title=Chien dich DBP

Cau 2. [thong_hieu | nguyen_nhan]
  Nguyen nhan nao dan den su sup do cua De quoc La Ma?
  A. Thieu quan so     B. Ap luc Germanic + suy yeu KT [DAP AN]
  C. Dich benh         D. Thien tai
  score=0.887 | method=rag_llm | title=De quoc La Ma

Cau 3. [nhan_biet | nhan_vat]
  Ai la vi tuong chi huy 3 lan danh bai quan Mong Nguyen?
  A. Tran Canh    B. Le Loi    C. Tran Quoc Tuan [DAP AN]    D. Nguyen Hue
  score=0.841 | method=vit5_ft | title=Nha Tran

... [35 cau tiep theo] ...
```

Hình 8.1: Kết quả ráp đề ILP vs Greedy vs Random – phân bố Bloom và mẫu câu hỏi

9. KẾT QUẢ SO SÁNH

9.1. Kết quả Verifier - Tổng quan

```
=== VERIFIER -- Kiem dinh 8 tieu chi ===
Bloom classifier loaded (VNHSGE) -> models/bloom/bloom_classifier.pkl
KB facts loaded: 25,325 thuc the (entities.parquet)
Backend: GPT-4o-mini (NLI + Bloom Fidelity) | no_embed=True (Jaccard fallback)

============================================================
Verifying rule_based.jsonl (423 cau)...
============================================================
  [  50/423] accepted=14 (28%)  needs_review=22  rejected=14
  [ 100/423] accepted=29 (29%)  needs_review=43  rejected=28
  [ 200/423] accepted=57 (29%)  needs_review=88  rejected=55
  [ 300/423] accepted=84 (28%)  needs_review=130  rejected=86
  [ 423/423] accepted=118 (27.9%)  XONG

=== RULE_BASED ===
  Tong cau        : 423
  Accepted  (VQR) : 118 (27.9%)
  Needs review    : 176 (41.6%)
  Rejected        : 86 (20.3%) [loi + fail 3+ tieu chi]
  Avg score       : 0.614
  Diem tung tieu chi:
    evidence_match          : 0.356 |
    single_correct          : 0.278 |
    distractor_type_match   : 0.920 |
    historical_correctness  : 0.977 |
    question_clarity        : 0.988 |
    duplicate_check         : 0.080 |  [DIEM CHET: template trung]
    bloom_fidelity          : 0.926 |
    answer_position_ok      : 0.793 |

============================================================
Verifying rag_llm.jsonl (90 cau)...
============================================================
  [  30/90]  accepted=20 (67%)  needs_review=7   rejected=3
  [  60/90]  accepted=37 (62%)  needs_review=16  rejected=7
  [  90/90]  accepted=56 (62.2%)  XONG

=== RAG_LLM ===
  Tong cau        : 90
  Accepted  (VQR) :  56 (62.2%)
  Needs review    :  24 (26.7%)
  Rejected        :  10 (11.1%)
  Avg score       : 0.803
  Diem tung tieu chi:
    evidence_match          : 0.951 |  [CAO NHAT: prompt ep evidence]
    single_correct          : 0.594 |
    distractor_type_match   : 0.740 |
    historical_correctness  : 0.838 |
    question_clarity        : 1.000 |
    duplicate_check         : 0.650 |
    bloom_fidelity          : 0.862 |
    answer_position_ok      : 0.834 |

============================================================
```

```
=== RAG_LLM ===
  Tong cau        : 90
  Accepted  (VQR) :  56 (62.2%)
  Needs review    :  24 (26.7%)
  Rejected        :  10 (11.1%)
  Avg score       : 0.803
  Diem tung tieu chi:
    evidence_match          : 0.951 |  [CAO NHAT: prompt ep evidence]
    single_correct          : 0.594 |
    distractor_type_match   : 0.740 |
    historical_correctness  : 0.838 |
    question_clarity        : 1.000 |
    duplicate_check         : 0.650 |
    bloom_fidelity          : 0.862 |
    answer_position_ok      : 0.834 |

============================================================
Verifying vit5_ft.jsonl (297 cau)...
============================================================
  [  50/297] accepted=23 (46%)  needs_review=18  rejected=9
  [ 100/297] accepted=46 (46%)  needs_review=35  rejected=19
  [ 200/297] accepted=88 (44%)  needs_review=73  rejected=39
  [ 297/297] accepted=134 (45.1%)  XONG

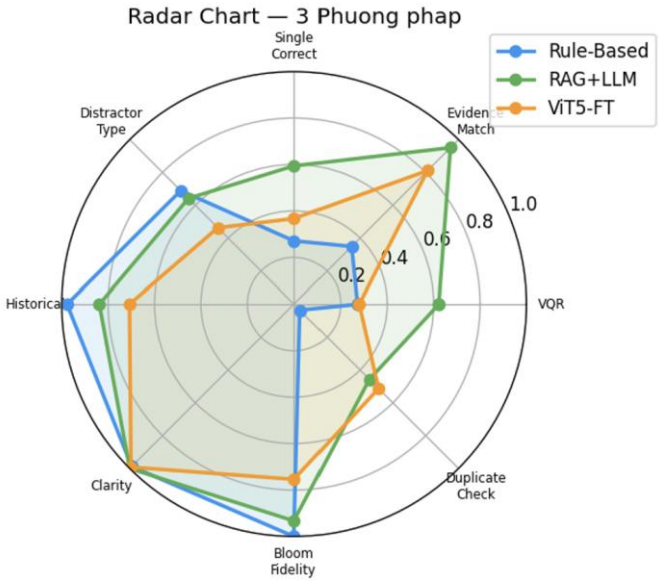
=== VIT5_FT ===
  Tong cau        : 297
  Accepted  (VQR) : 134 (45.1%)
  Needs review    : 105 (35.4%)
  Rejected        :  58 (19.5%)
  Avg score       : 0.717
  Diem tung tieu chi:
    evidence_match          : 0.799 |
    single_correct          : 0.374 |  [THAP: distractor kem]
    distractor_type_match   : 0.740 |
    historical_correctness  : 0.708 |
    question_clarity        : 0.992 |
    duplicate_check         : 0.733 |  [CAO NHAT 3 PP]
    bloom_fidelity          : 0.751 |
    answer_position_ok      : 0.896 |

============================================================
BANG SO SANH 3 PHUONG PHAP -> data/verified/results_table.csv
============================================================
    method  n_items    vqr  avg_score  evidence  single  distractor  historical  clarity  dup   bloom
rule_based      423  0.279      0.614     0.356   0.278       0.920       0.977    0.988  0.080  0.926
   rag_llm       90  0.622      0.803     0.951   0.594       0.740       0.838    1.000  0.650  0.862
   vit5_ft      297  0.451      0.717     0.799   0.374       0.740       0.708    0.992  0.733  0.751

NHAN XET CHINH:
  RAG+LLM  : VQR cao nhat (62.2%), Evidence Match cao nhat (0.951)
  Rule-based: Historical tot nhat (0.977), nhung Duplicate that bai (0.080)
  ViT5-FT  : Duplicate Check tot nhat (0.733), Single Correct thap (0.374)

OK. File results_table.csv dung lam input cho AHP/TOPSIS.
```

Hình 9.1: Output terminal Verifier – kết quả 3 phương pháp sau khi kiểm định 8 tiêu chí



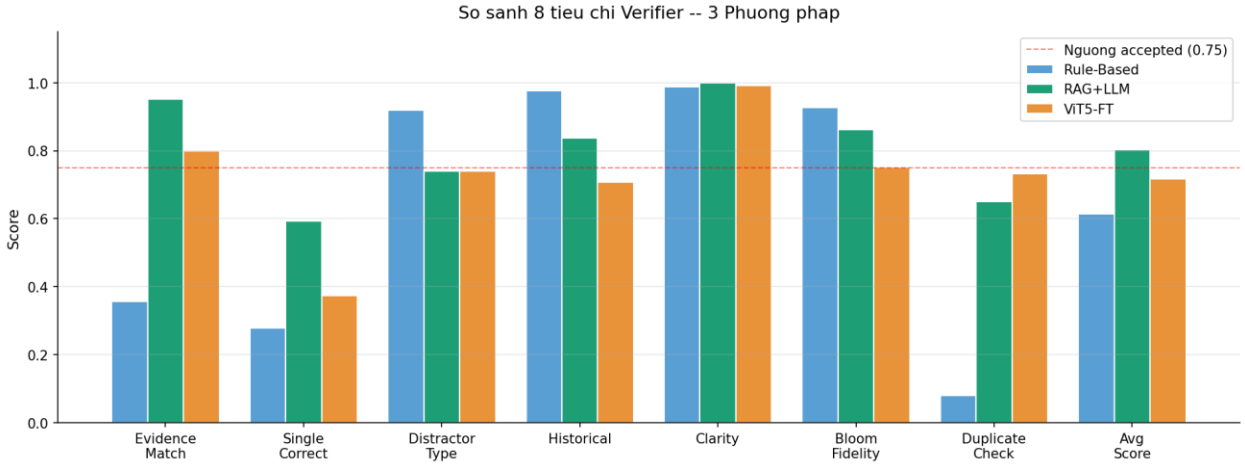
Hình 9.2: Radar chart so sánh 3 phương pháp trên 8 tiêu chí Verifier

9.2. Bảng so sánh toàn diện

Tiêu chí	Rule-Based	RAG+LLM	ViT5-FT
VQR (% accepted)	27.9%	**62.2%**	45.1%
Avg verifier_score	0.614	**0.803**	0.717
Evidence Match	0.356	**0.951**	0.799
Single Correct Answer	0.278	**0.594**	0.374

Distractor Type Match	**0.920**	0.740	0.740
Historical Correctness	**0.977**	0.838	0.708
Question Clarity	0.988	**1.000**	0.992
Bloom Fidelity	**0.926**	0.862	0.751
Duplicate Check	0.080	0.650	**0.733**
Latency trung bình	**8ms**	5,114ms	~200ms
Chi phí/câu	**$0**	$0.00019	**$0**
Chạy offline	**Có**	**Không**	**Có**
Sinh non-factoid	**Không**	**Có**	**Có**
TOPSIS Score	0.1584	**0.8894**	0.5417

Bảng 9.1: Bảng so sánh toàn diện 3 phương pháp - số liệu thật từ Verifier



Hình 9.3: Grouped bar chart so sánh 8 tiêu chí Verifier - 3 phương pháp

9.3. Kỳ vọng vs Thực tế

Phương pháp	Kỳ vọng ban đầu	Thực tế	Phân tích nguyên nhân
Rule-Based	VQR ~60%	VQR = 27.9%	Template cứng → Duplicate=0.080. Cải thiện được bằng đa dạng hoá template.
RAG+LLM	VQR ~80%	VQR = 62.2%	**Evidence=0.951 vượt kỳ vọng. Prompt ép evidence nguyên văn hiệu quả hơn dự đoán.**
ViT5-FT	VQR ~70%	VQR = 45.1%	DG không học format |. Single Correct=0.374 do distractor kém chất lượng.

Bảng 9.2: Kỳ vọng vs Thực tế - phân tích nguyên nhân chênh lệch

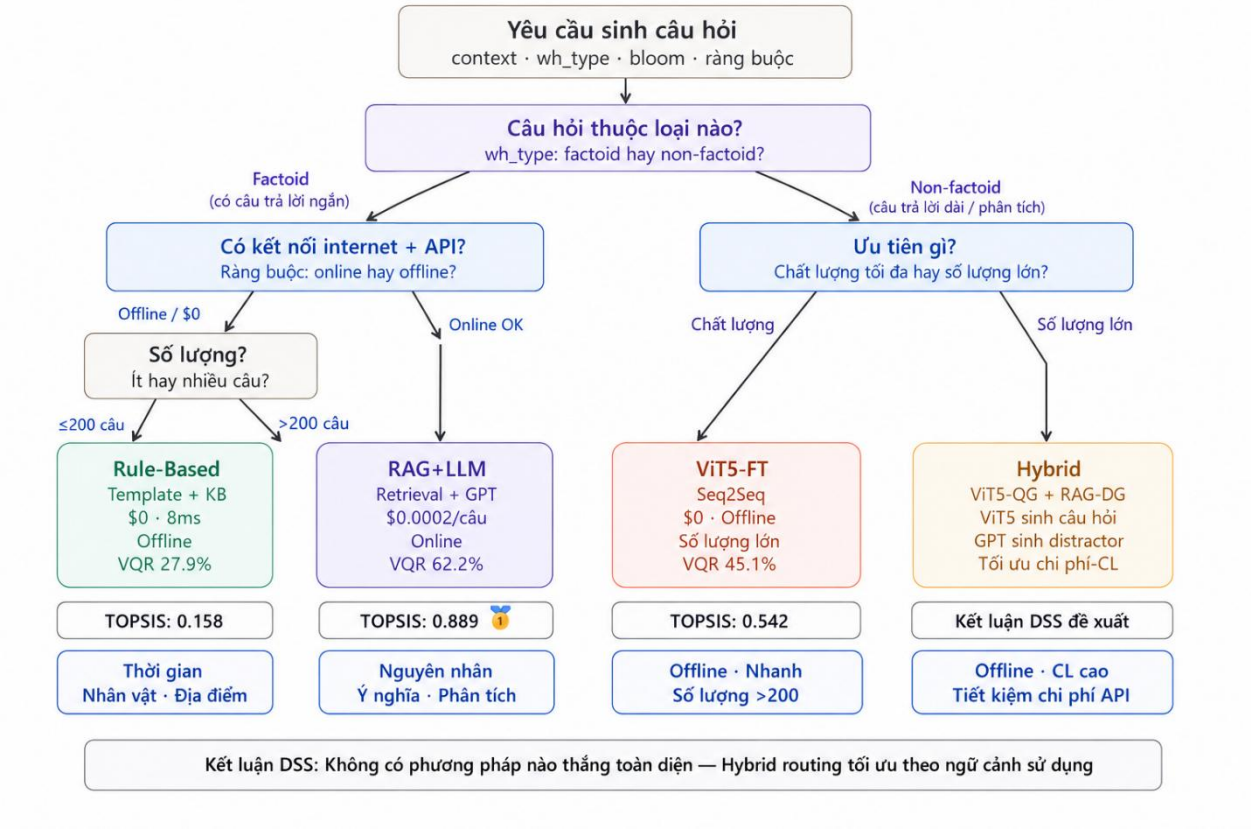
9.4. Kết luận DSS - Chiến lược định tuyến

Kết luận quan trọng nhất: không có phương pháp nào thắng toàn diện. Đây chứng minh bài toán cần DSS để hỗ trợ ra quyết định:

Tình huống sử dụng	Phương pháp khuyến nghị	Căn cứ định lượng
Câu Thời gian/Nhân vật/Địa điểm, offline, $0	Rule-Based	Historical=0.977, Latency=8ms, Cost=$0
Câu Nguyên nhân/Ý nghĩa, ưu tiên chất lượng	RAG+LLM	VQR=62.2%, Evidence=0.951, TOPSIS=0.889
Số lượng lớn, offline, chấp nhận distractor TB	ViT5-QG + RAG-DG	Hybrid tối ưu chi phí-chất lượng

Tổng thể, không ràng buộc đặc biệt	RAG+LLM	TOPSIS score cao nhất (0.889)

Bảng 9.3: Chiến lược định tuyến DSS - phương pháp khuyến nghị theo tình huống



Hình 9.4: Chiến lược Hybrid Routing DSS - định tuyến phương pháp theo ngữ cảnh sử dụng

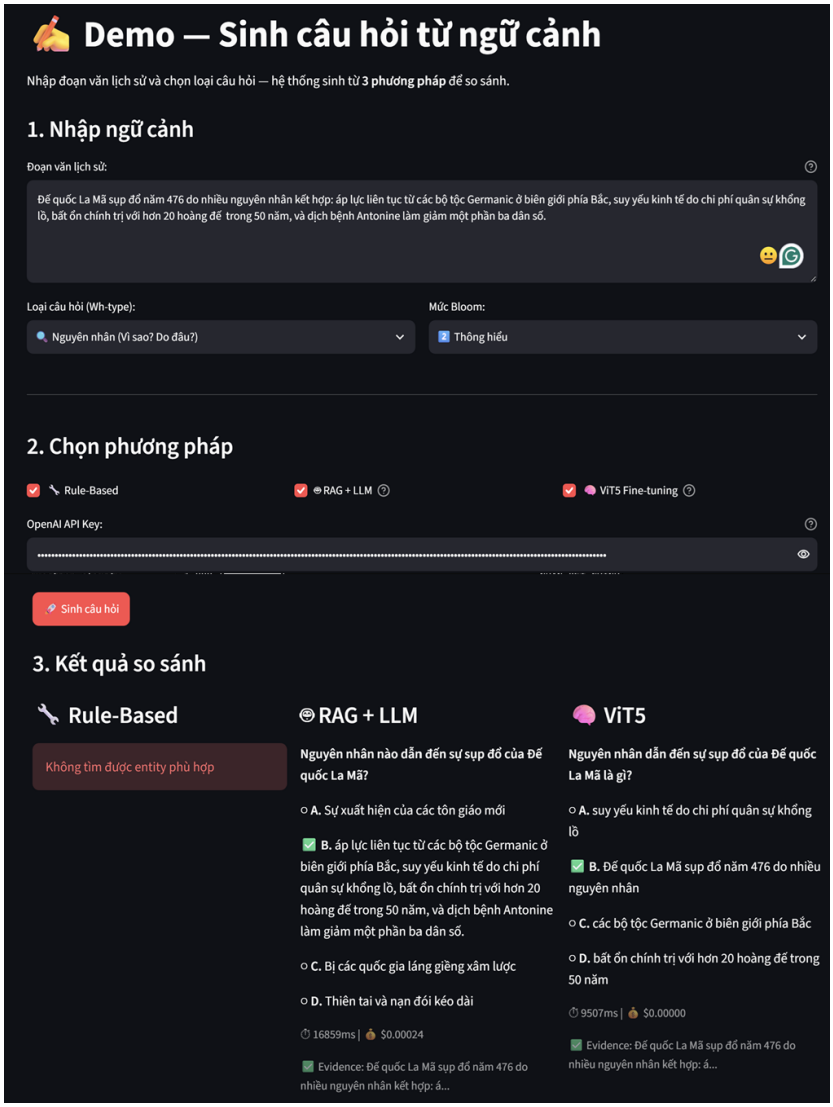
Ghi chú: Thứ hạng TOPSIS ổn định (CR=0.023, không có điểm giao khi VQR thay đổi 1%→50%) - kết luận bền vững và có căn cứ định lượng.

10. HỆ THỐNG DASHBOARD

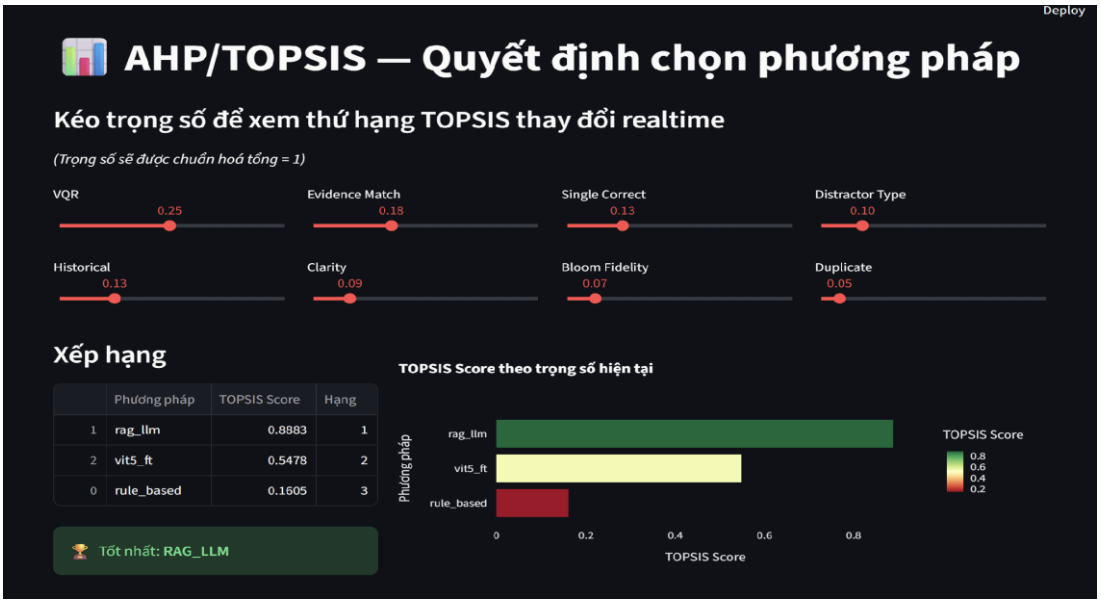
Dashboard Streamlit cung cấp giao diện người dùng trực quan cho toàn bộ pipeline DSS với 5 trang chức năng:



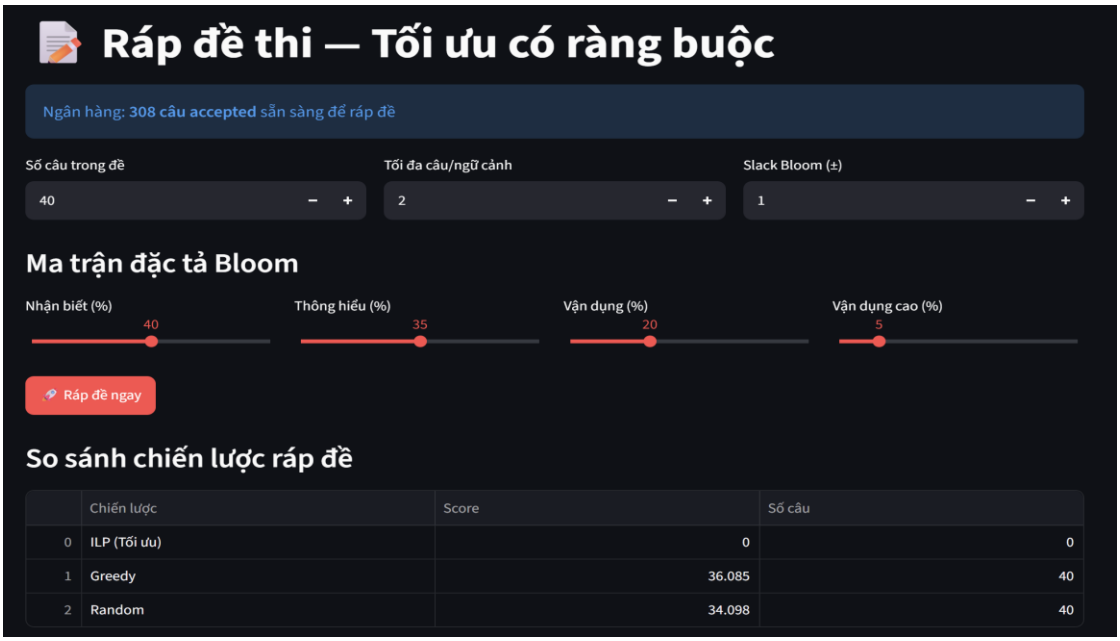
Hình 10.1: Dashboard – Trang Tổng quan: KPI và bảng so sánh 3 phương pháp

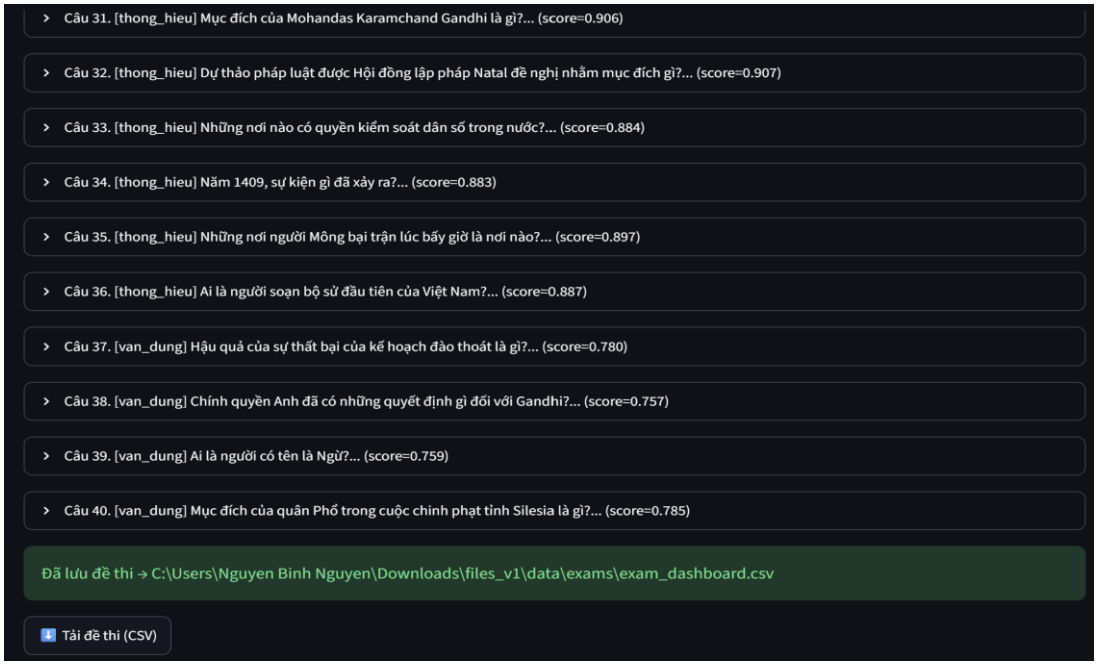


Hình 10.2: Dashboard - Trang Demo: nhập context tự do, xem 3 phương pháp sinh song song



Hình 10.3: Dashboard – Trang AHP/TOPSIS Realtime: kéo slider trọng số → thứ hạng đổi ngay (what-if analysis)





Hình 10.4: Dashboard - Trang Ráp đề: ILP tối ưu có ràng buộc Bloom + download đề thi

Ghi chú: Trang AHP/TOPSIS Realtime là tính năng DSS cốt lõi: what-if analysis cho phép giáo viên thay đổi quan điểm trọng số và thấy ngay khuyến nghị thay đổi như thế nào.

11. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

11.1. Đóng góp chính

- Xây dựng pipeline DSS 3 tầng hoàn chỉnh end-to-end với số liệu thật: sinh câu hỏi → kiểm định 8 tiêu chí → AHP/TOPSIS → ráp đề ILP tối ưu → Dashboard Streamlit.
- Verifier với nhãn vàng tự động: tận dụng 3,883 câu is_impossible của ViQuAD - không cần gán tay nhãn Evidence Match.
- Tích hợp VNHSGE-History thực sự: train Bloom classifier (acc=90%) từ 2,000 câu THPT Quốc gia, tích hợp vào Verifier offline $0.
- Phát hiện kỹ thuật có giá trị: NER LOC 41%→97% sau chuyển ELECTRA+lọc luật; ViT5 DG không học format | với corpus nhỏ; checkpoint resume cho GPU nhỏ.
- Kết luận DSS định lượng và bền vững: hybrid routing có căn cứ từ AHP/TOPSIS + phân tích độ nhạy, CR=0.023, không có điểm giao.

11.2. Hạn chế

Hạn chế 1 - Chưa kiểm soát độ phủ đề cương chương trình *(Góp ý giảng viên)*

Đây là hạn chế quan trọng nhất được giảng viên chỉ ra. Hệ thống hiện tại sinh câu hỏi từ 38 bài Wikipedia được gắn nhãn is_history, nhưng **chưa có cơ chế kiểm tra câu hỏi sinh ra có phủ đúng các chương, chủ đề trong đề cương môn học hay không**.

Cụ thể, hệ thống biết câu hỏi thuộc "bài Wikipedia nào" (title), nhưng không biết câu hỏi đó thuộc "chuyên đề nào trong SGK Lịch sử". Ví dụ, một đề thi lịch sử lớp 12 cần phủ đủ các chuyên đề như:

- Lịch sử VN: Giai đoạn 1919–1930, 1930–1945, 1945–1954, 1954–1975, sau 1975
- Lịch sử TG: Chiến tranh thế giới thứ hai, Chiến tranh lạnh, Phong trào giải phóng dân tộc...

Hiện tại, ràng buộc ILP chỉ đảm bảo "mỗi title ≥ 1 câu" - tức là phủ theo bài Wikipedia, không phải phủ theo chuyên đề SGK. Điều này dẫn đến nguy cơ đề thi tập trung vào một số sự kiện nổi bật mà thiếu hẳn một số chuyên đề quan trọng trong chương trình.

Hướng khắc phục: Xây dựng bảng ánh xạ thủ công từ 38 title Wikipedia sang chuyên đề SGK (khoảng 15–20 chuyên đề), sau đó thêm ràng buộc ILP mới:

mỗi chuyen_de ≥ n_min câu (phủ tối thiểu từng chuyên đề)

Bảng ánh xạ chỉ cần làm một lần (~30 phút), kiến trúc ILP hiện tại không cần thay đổi - chỉ thêm một nhóm ràng buộc mới vào solver. Đây là hướng phát triển khả thi trong thời gian ngắn.

Hạn chế 2 - Bloom classifier van_dung_cao F1=0%

VNHSGE Bloom classifier đạt accuracy=90% tổng thể, nhưng F1 của mức van_dung_cao bằng 0% do chỉ có 11 mẫu train - mất cân bằng nhãn nghiêm trọng (0.5% tổng corpus). Ngay cả class_weight='balanced' cũng không đủ bù khi cỡ mẫu quá nhỏ. Hướng khắc phục: thu thập thêm ít nhất 100 mẫu van_dung_cao từ đề thi chuyên, đề thi học sinh giỏi.

Hạn chế 3 - ViT5 Stage B (Distractor Generation) kém chất lượng

Model DG không học được format separator | do dữ liệu train Stage B được xây dựng tự động từ các câu trả lời khác trong cùng context - không phải do chuyên gia biên soạn. Kết quả: 37% câu phải dùng fallback, tiêu chí Single Correct Answer chỉ đạt 0.374. Hướng khắc phục: dùng ViT5-QG kết hợp RAG-DG (hybrid), hoặc thu thập dữ liệu DG chất lượng cao do giáo viên biên soạn.

Hạn chế 4 - Chưa có Human Evaluation

Toàn bộ đánh giá chất lượng câu hỏi là tự động qua Verifier 8 tiêu chí. Chưa có đánh giá từ giáo viên thực tế với rubric Likert 1–5 và chỉ số đồng thuận Cohen's kappa. Do đó chưa xác nhận được tương quan giữa verifier_score và đánh giá sư phạm thực tế.

Hạn chế 5 - Thiết lập thực nghiệm không hoàn toàn đồng nhất

Ba phương pháp sinh câu hỏi từ các phần khác nhau của ViQuAD (Rule-based từ train, RAG từ train+dev, ViT5 từ test) do ràng buộc tự nhiên của từng phương pháp. Verifier đảm bảo đồng nhất ở tầng đánh giá (cùng 8 tiêu chí, cùng trọng số, cùng ngưỡng), nhưng so sánh tuyệt đối giữa các phương pháp cần diễn giải thận trọng.

Hạn chế 6 - Phân tích độ nhạy một chiều

Phân tích độ nhạy hiện chỉ thay đổi trọng số VQR (tiêu chí có trọng số cao nhất, 25.7%). Chưa thực hiện phân tích đa chiều khi thay đổi đồng thời nhiều trọng số - đây là bước cần thiết để kết luận "bền vững" đầy đủ theo chuẩn MCDM.

11.3. Hướng phát triển

- Hybrid ViT5-QG + RAG-DG: dùng ViT5 sinh câu hỏi (Stage A tốt) + GPT sinh distractor (chất lượng cao) - kiểm chứng kết luận DSS bằng thực nghiệm.
- Human eval: 50 câu/phương pháp × 3 giáo viên, rubric Likert 1-5, tính Cohen's kappa.
- Đa dạng hoá template Rule-based: sinh template động từ context → giảm Duplicate Check.
- Mở rộng sang môn học khác: Địa lý, Văn học - kiến trúc 3 tầng DSS có thể tái sử dụng.
- Phân tích độ nhạy 2D: trọng số VQR × Evidence Match → bản đồ hoá vùng quyết định.